Institución Universitaria
Reacreditada en Alta Calidad

HERRAMIENTAS DE VISUALIZACIÓN DE DATOS

INTRODUCCIÓN A LA CIENCIA DE DATOS

530202018

www.itm.edu.co

Vigilado Mineducación

HERRAMIENTAS DE VISUALIZACIÓN DE DATOS

En general, los datos están en todas partes: negocios, ciencia, salud, deportes. El reto de la ciencia de datos es entenderlos y explicarlos de forma clara.

Vigilada Mineducación

HERRAMIENTAS DE VISUALIZACIÓN DE DATOS

En general, los datos están en todas partes: negocios, ciencia, salud, deportes. El reto de la ciencia de datos es entenderlos y explicarlos de forma clara.

Las herramientas de análisis y visualización ayudan a transformar tablas en historias con sentido, algunas de las principales son:

- Medidas estadísticas
- Histogramas
- Diagramas de dispersión (scatter plots)

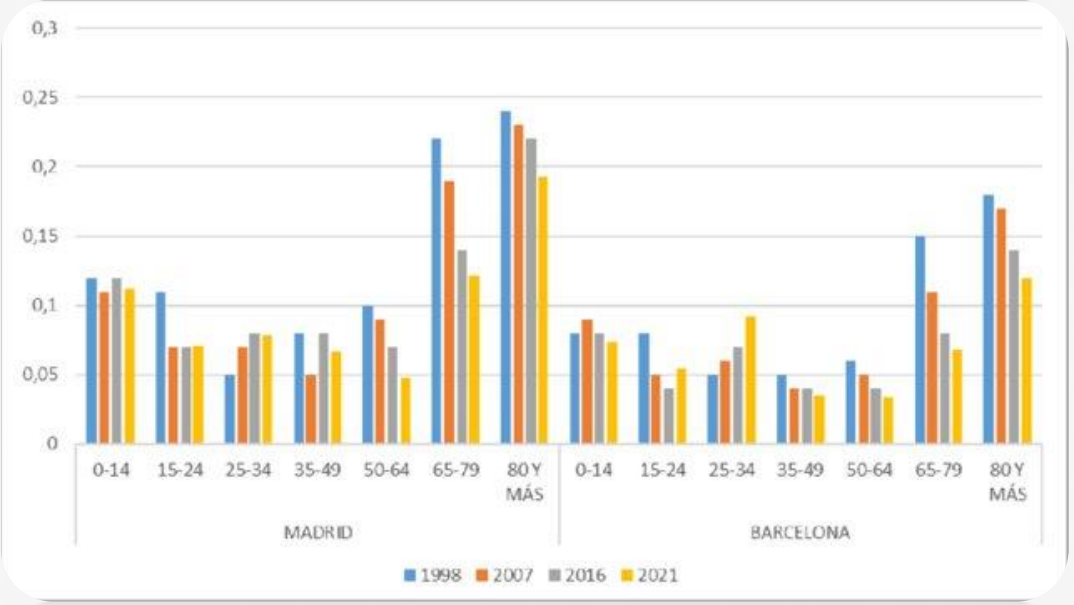

Vigilada Mineducación

https://www.researchgate.net/publication/373745673_cambiante_localizacion_de_la_poblacion_mayor_en_las_areas_metropolitanas_de_Barcelona_y_Madrid_Analisis_comparativo_de_tendencias_espaciales

- **Medidas estadísticas**

Las medidas estadísticas son valores que resumen y describen las características principales de un conjunto de datos. Ayudan a entender la información de manera rápida y sencilla.

Se dividen principalmente en dos categorías:

- Medidas de tendencia central
- Medidas de dispersión

Vigilada Mineducación

- **Medidas estadísticas**
  - Medidas de tendencia central

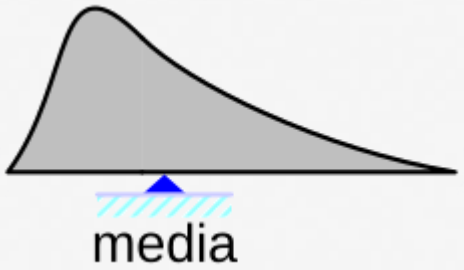

Media:

Es el promedio de los datos. Es ideal para datos numéricos sin valores extremos (atípicos), ya que estos distorsionan el resultado.

Vigilada Mineducación

- **Medidas estadísticas**
  - Medidas de tendencia central

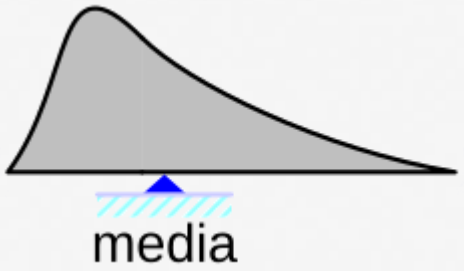

Media:

Es el promedio de los datos. Es ideal para datos numéricos sin valores extremos (atípicos), ya que estos distorsionan el resultado.

Mediana:

Es el **valor que se encuentra justo en el medio** de un conjunto de datos ordenado. No se ve afectada por los valores atípicos.

Vigilada Mineducación

- **Medidas estadísticas**
  - Medidas de tendencia central

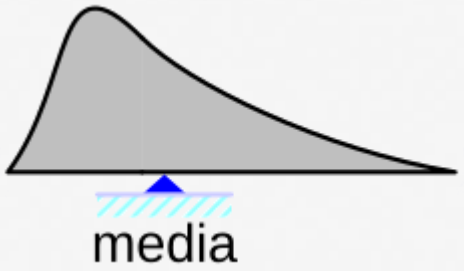

Media:

Es el promedio de los datos. Es ideal para datos numéricos sin valores extremos (atípicos), ya que estos distorsionan el resultado.

Mediana:

Es el **valor que se encuentra justo en el medio** de un conjunto de datos ordenado. No se ve afectada por los valores atípicos.

Moda:

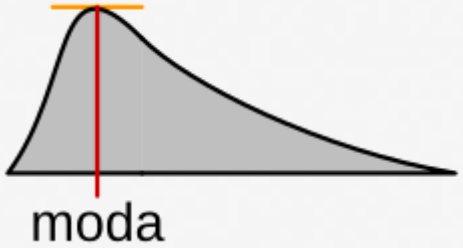

Es el **valor que más se repite** en el conjunto de datos.

Vigilada Mineducación

- **Medidas estadísticas**
  - Medidas de dispersión (o variabilidad)

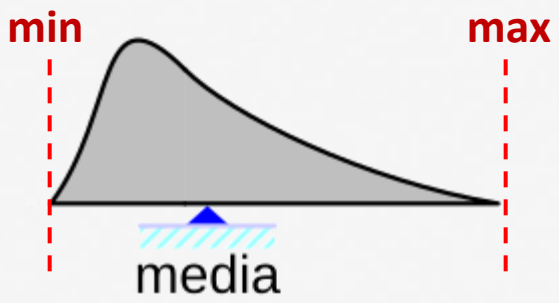

Rango:

Es la diferencia entre el **valor máximo y el valor mínimo**.

Vigilada Mineducación

- **Medidas estadísticas**
  - Medidas de dispersión (o variabilidad)

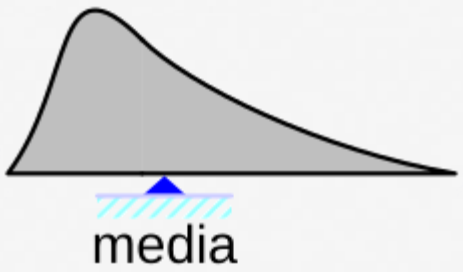

Rango:

Es la diferencia entre el **valor máximo y el valor mínimo**.

Varianza (s^2)

Mide qué tan lejos está cada valor del promedio. Una varianza alta significa que los datos están muy dispersos, mientras que si es baja indica que los datos tienden a estar cerca de la media.

Vigilada Mineducación

- **Medidas estadísticas**
  - Medidas de dispersión (o variabilidad)

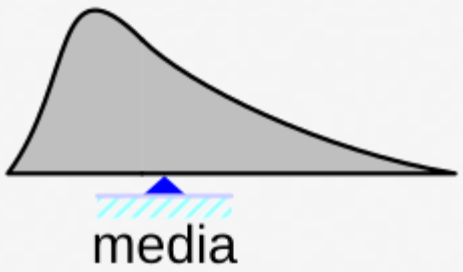

Rango:

Es la diferencia entre el **valor máximo y el valor mínimo**.

Varianza (s^2)

Mide qué tan lejos está cada valor del promedio. Una varianza alta significa que los datos están muy dispersos, mientras que si es baja indica que los datos tienden a estar cerca de la media.

Desviación Estándar ($s = \sqrt{s^2}$)

Al aplicar la raíz cuadrada a la varianza, volvemos el valor a su unidad original, lo que hace que el dato sea mucho más intuitivo.

Vigilada Mineducación

- **Histogramas**

Un histograma es un gráfico de barras que visualiza la distribución de frecuencia de un conjunto de datos numéricos continuos. Ayuda a entender la forma, el centro y la dispersión de los datos.

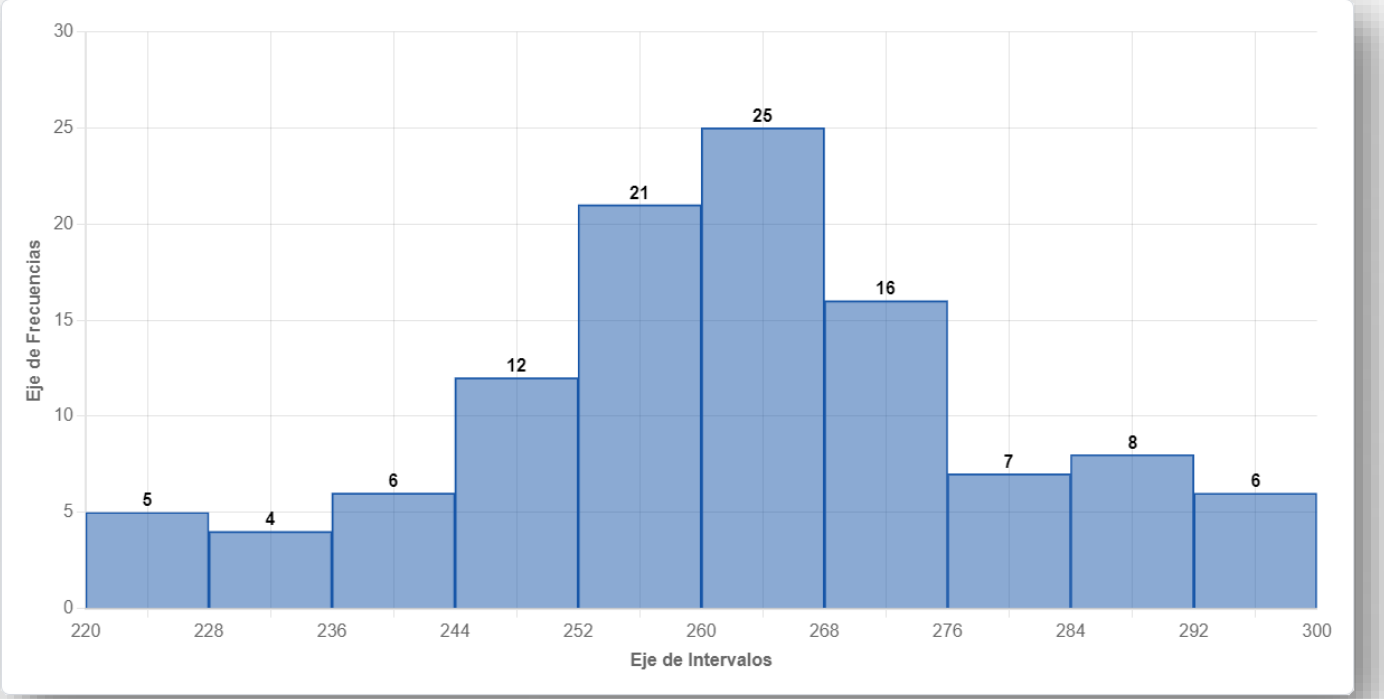

Vigilada Mineducación

- **Histogramas**

Los histogramas permiten identificar:

➢ **La forma de la distribución**: Si es simétrica (como una campana), sesgada (cola larga) a la derecha o sesgada a la izquierda.

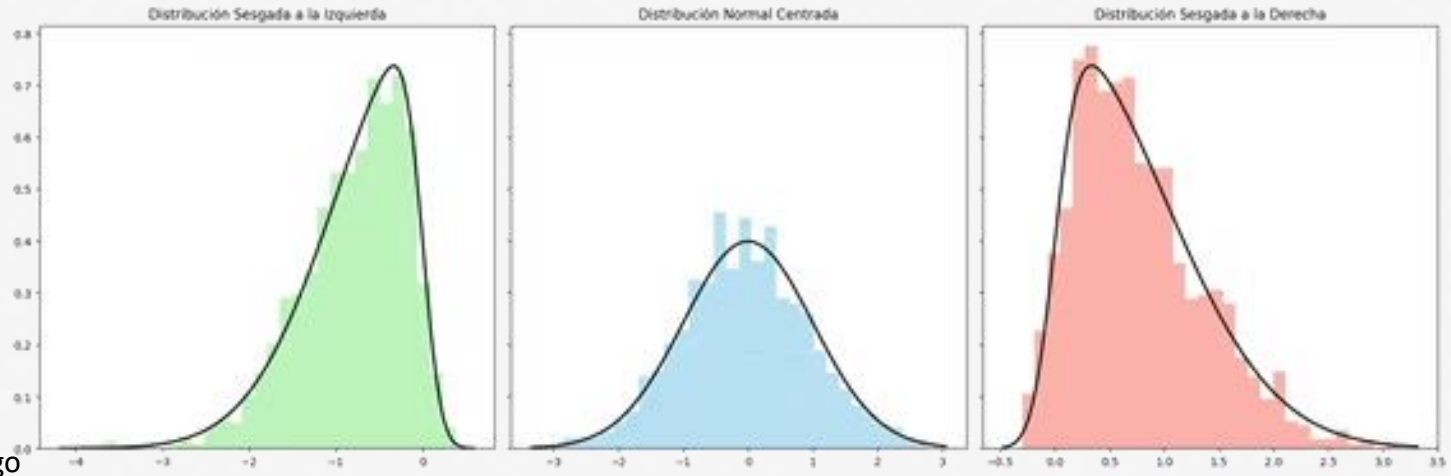

https://www.chreinvent.com/recursos/sesgo

Vigilada Mineducación

- **Histogramas**

Los histogramas permiten identificar:

- **La forma de la distribución**: Si es simétrica (como una campana), sesgada (cola larga) a la derecha o sesgada a la izquierda.
- **Concentración de los datos**: Dónde se agrupan la mayoría de los valores.

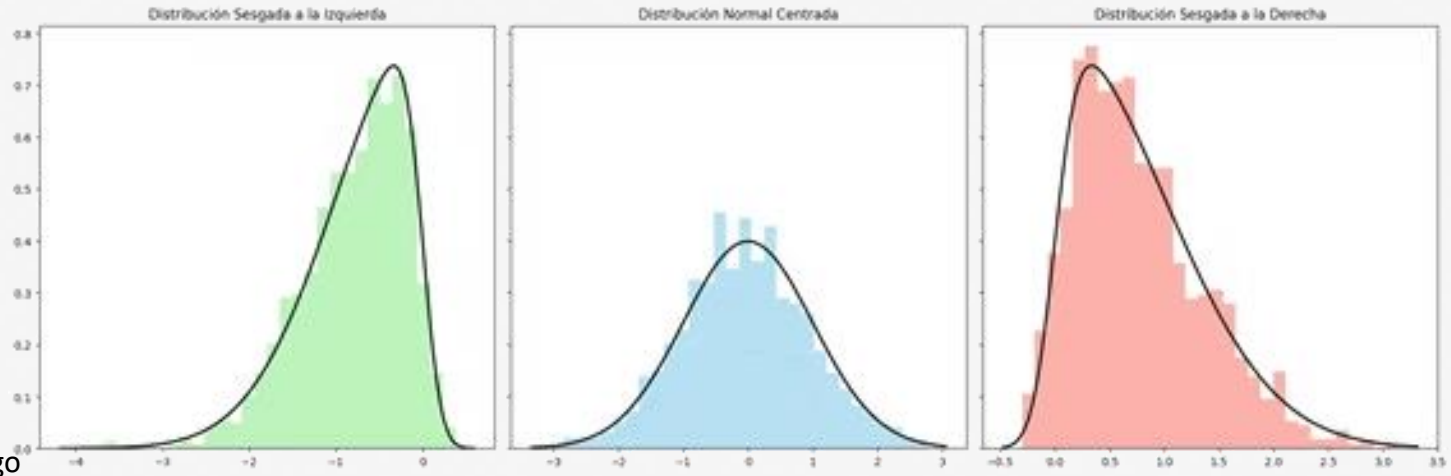

https://www.chreinvent.com/recursos/sesgo

Vigilada Mineducación

- **Histogramas**

Los histogramas permiten identificar:

- **La forma de la distribución**: Si es simétrica (como una campana), sesgada (cola larga) a la derecha o sesgada a la izquierda.
- **Concentración de los datos**: Dónde se agrupan la mayoría de los valores.
- **Valores atípicos (Outliers)**: Barras aisladas y lejanas del resto.

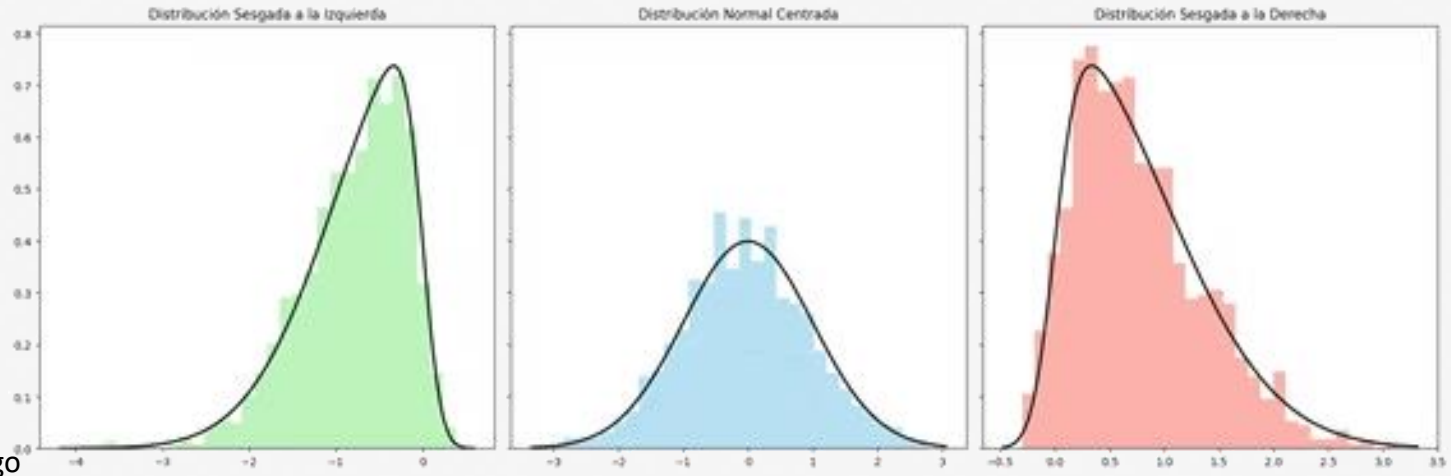

Vigilada Mineducación

https://www.chreinvent.com/recursos/sesgo

- **Diagramas de dispersión (Scatter plots)**

Son gráficos que se utiliza para **visualizar la relación** entre dos variables numéricas.

Cada punto en el gráfico representa una observación en los datos, con su posición determinada por los valores de las dos variables (una en el **eje X** y otra en el **eje Y**).

Vigilada Mineducación

- **Diagramas de dispersión (Scatter plots)**

Los Diagramas de dispersión permiten identificar:

➢ **Correlación**: Es su principal utilidad, ya que dice cómo se comporta una variable cuando la otra cambia. Puede clasificarse como **correlación positiva, correlación negativa, sin correlación** o **sin correlación lineal.**

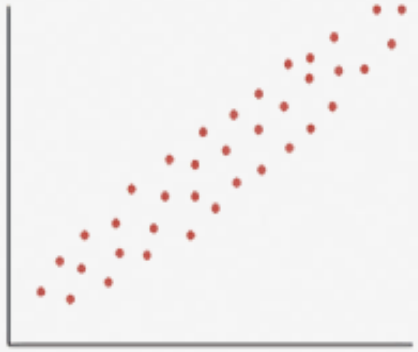

3. Correlación lineal positiva alta

Vigilada Mineducación

- **Diagramas de dispersión (Scatter plots)**

Los Diagramas de dispersión permiten identificar:

➢ **Correlación**: Es su principal utilidad, ya que dice cómo se comporta una variable cuando la otra cambia. Puede clasificarse como **correlación positiva, correlación negativa, sin correlación** o **sin correlación lineal.**

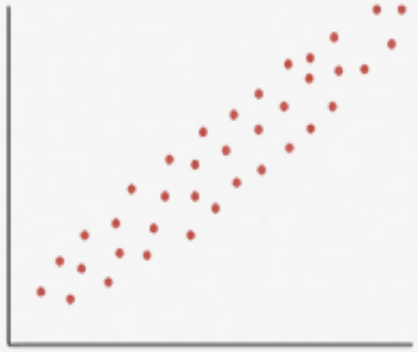

3. Correlación lineal positiva alta

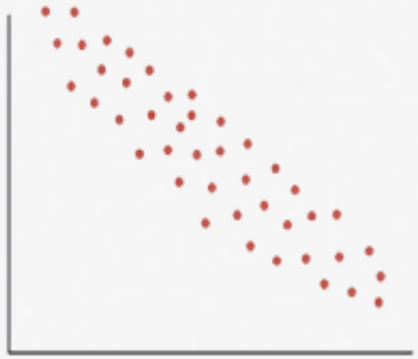

5. Correlación lineal negativa alta

Vigilada Mineducación

- **Diagramas de dispersión (Scatter plots)**

Los Diagramas de dispersión permiten identificar:

➢ **Correlación**: Es su principal utilidad, ya que dice cómo se comporta una variable cuando la otra cambia. Puede clasificarse como **correlación positiva, correlación negativa, sin correlación** o **sin correlación lineal.**

Vigilada Mineducación

- **Diagramas de dispersión (Scatter plots)**

Los Diagramas de dispersión permiten identificar:

➢ **Correlación**: Es su principal utilidad, ya que dice cómo se comporta una variable cuando la otra cambia. Puede clasificarse como **correlación positiva, correlación negativa, sin correlación** o **sin correlación lineal.**

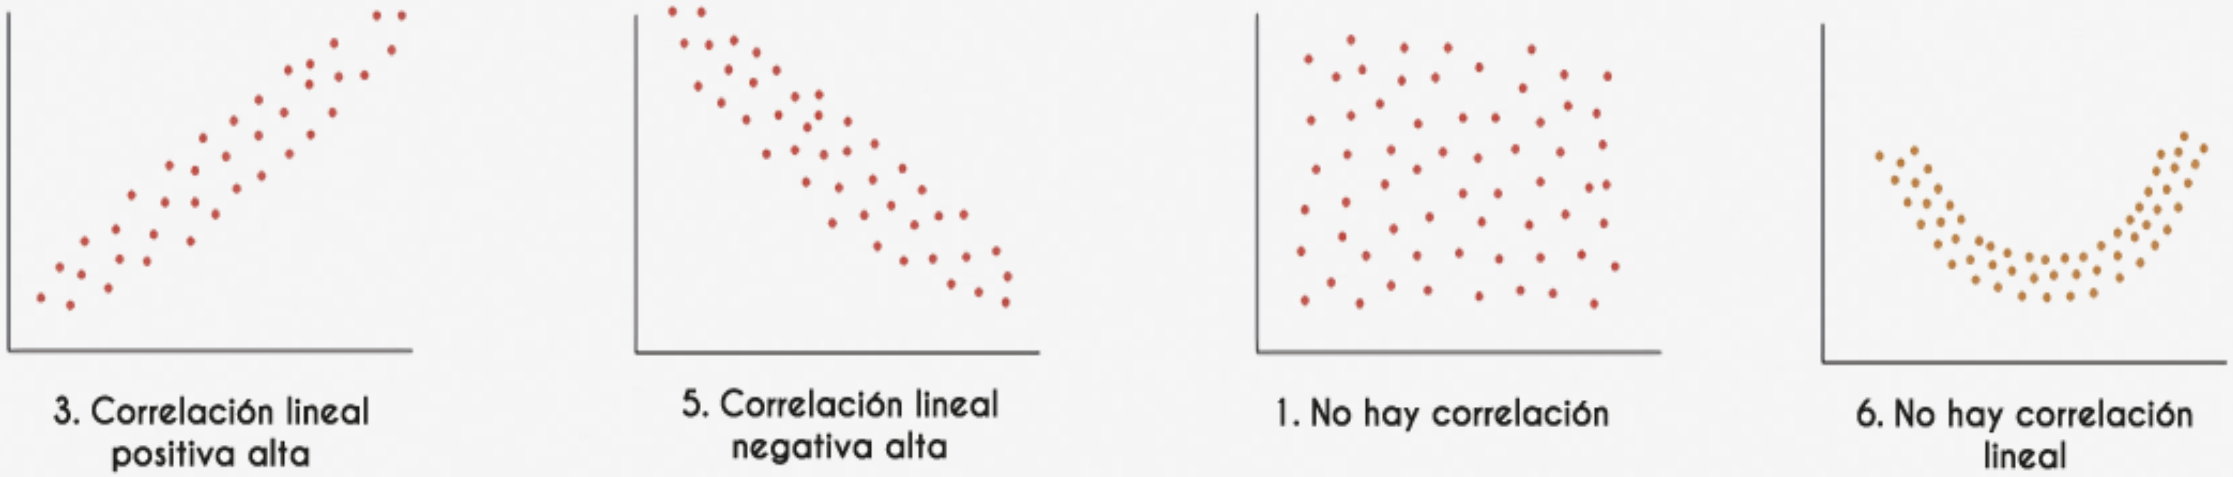

Vigilada Mineducación

- **Diagramas de dispersión (Scatter plots)**

Los Diagramas de dispersión permiten identificar:

Fuerza de la relación: Si los puntos están muy agrupados formando una línea clara, la relación es fuerte. Si están muy dispersos, es débil.

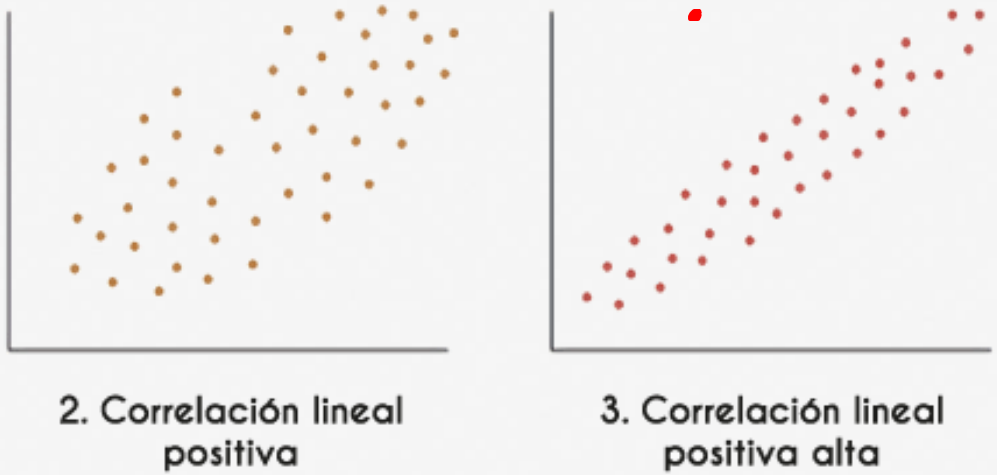

Vigilada Mineducación

- **Diagramas de dispersión (Scatter plots)**

Los Diagramas de dispersión permiten identificar:

Fuerza de la relación: Si los puntos están muy agrupados formando una línea clara, la relación es fuerte. Si están muy dispersos, es débil.

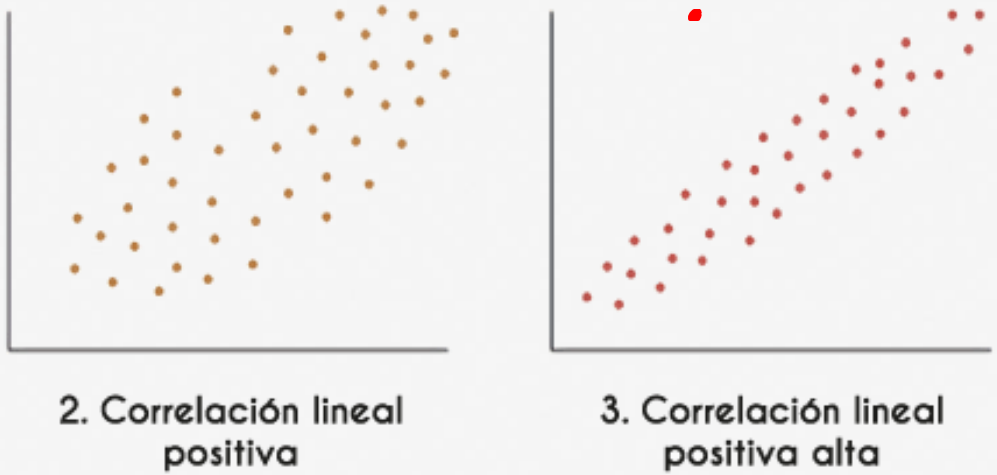

Identificación de outliers : Puntos que se alejan del patrón general del resto de los datos.

Vigilada Mineducación

HERRAMIENTAS DE VISUALIZACIÓN DE DATOS

Una vez que entendemos nuestros datos a través de las medidas estadísticas, el siguiente paso es visualizarlos para descubrir patrones y comunicar nuestros hallazgos.

Existen muchas herramientas para crear gráficos como histogramas y diagramas de dispersión, pero estas son un excelente punto de partida:

- Microsoft Excel
- Orange Data Mining
- Power BI
- Python

Vigilada Mineducación

- **Microsoft Excel**

Es la herramienta más accesible y conocida. Excel es ideal para análisis rápidos, tareas sencillas y crear gráficos básicos para informes.

Fortalezas:

- Fácil de usar.
- Ampliamente disponible:.
- Rápido para visualizaciones simples

Limitaciones:

No es la mejor opción para manejar grandes volúmenes de datos (Big Data) o para crear visualizaciones interactivas y complejas.

Vigilada Mineducación

- **Power BI**

Es una herramienta de **Business Intelligence**, diseñada específicamente para el análisis y la visualización de datos. Es ideal para crear dashboards interactivos y reportes profesionales.

Fortalezas:

- Interactividad.
- Conexión a múltiples fuentes.
- Visualizaciones avanzadas: Ofrece una mayor variedad y personalización de gráficos que Excel.

Limitaciones: La curva de aprendizaje es más compleja que Excel, pero mucho más potente.

Vigilada Mineducación

- **Python (con librerías como Pandas, Matplotlib y Seaborn)**

Es un **lenguaje de programación** versátil y potente y es el estándar en la ciencia de datos. Usando sus librerías especializadas, las posibilidades son casi infinitas. Es ideal para análisis de datos complejos, personalización de los gráficos y automatización de reportes.

Fortalezas:

- Flexibilidad absoluta.
- Integración con análisis avanzados.
- Automatización.

Limitaciones: Requiere conocimientos de programación, por lo que es la opción más avanzada de las tres.

Vigilada Mineducación

- **Orange Data Mining**

Herramienta de código abierto para la minería de datos, el aprendizaje automático (Machine Learning) y la visualización interactiva (programación visual).

Fortalezas:

- Interfaz visual intuitiva.
- Análisis exploratorio interactivo.
- Ideal para Machine Learning.

Limitaciones:

Está limitado por las características del computador y no es ideal para el despliegue de dashboards empresariales a gran escala.

Vigilada Mineducación

- **Orange Data Mining**

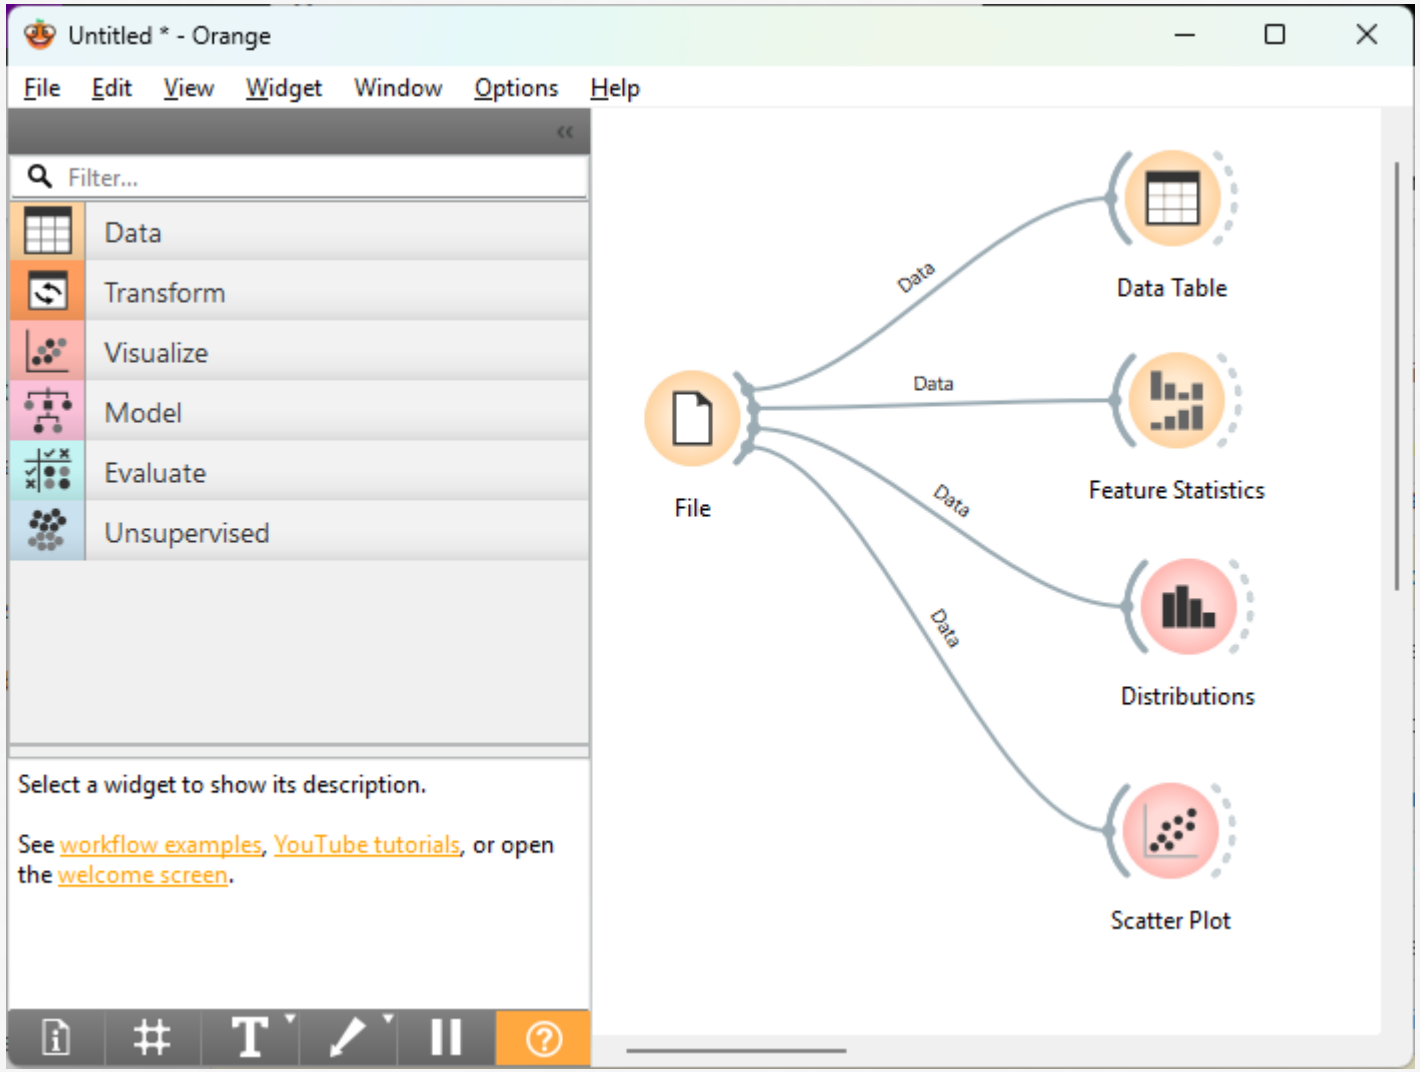

Vigilada Mineducación

➢ Ejemplo

Analizar el dataset ‘Iris’ usando Orange Data Mining.

Este dataset contiene mediciones morfológicas de **150 flores** de la planta Iris, divididas en tres especies distintas.

Es un dataset "limpio", sin valores nulos, por lo que no necesita preprocesamiento.

	iris	petal length	sepal length	sepal width	petal width
1	Iris-setosa	1.4	5.1	3.5	0.2
2	Iris-setosa	1.4	4.9	3.0	0.2
3	Iris-setosa	1.3	4.7	3.2	0.2
4	Iris-setosa	1.5	4.6	3.1	0.2
5	Iris-setosa	1.4	5.0	3.6	0.2
6	Iris-setosa	1.7	5.4	3.9	0.4
7	Iris-setosa	1.4	4.6	3.4	0.3
8	Iris-setosa	1.5	5.0	3.4	0.2
9	Iris-setosa	1.4	4.4	2.9	0.2
10	Iris-setosa	1.5	4.9	3.1	0.1

Vigilada Mineducación

➢Ejemplo

Analizar el dataset ‘Iris’ usando Orange Data Mining.

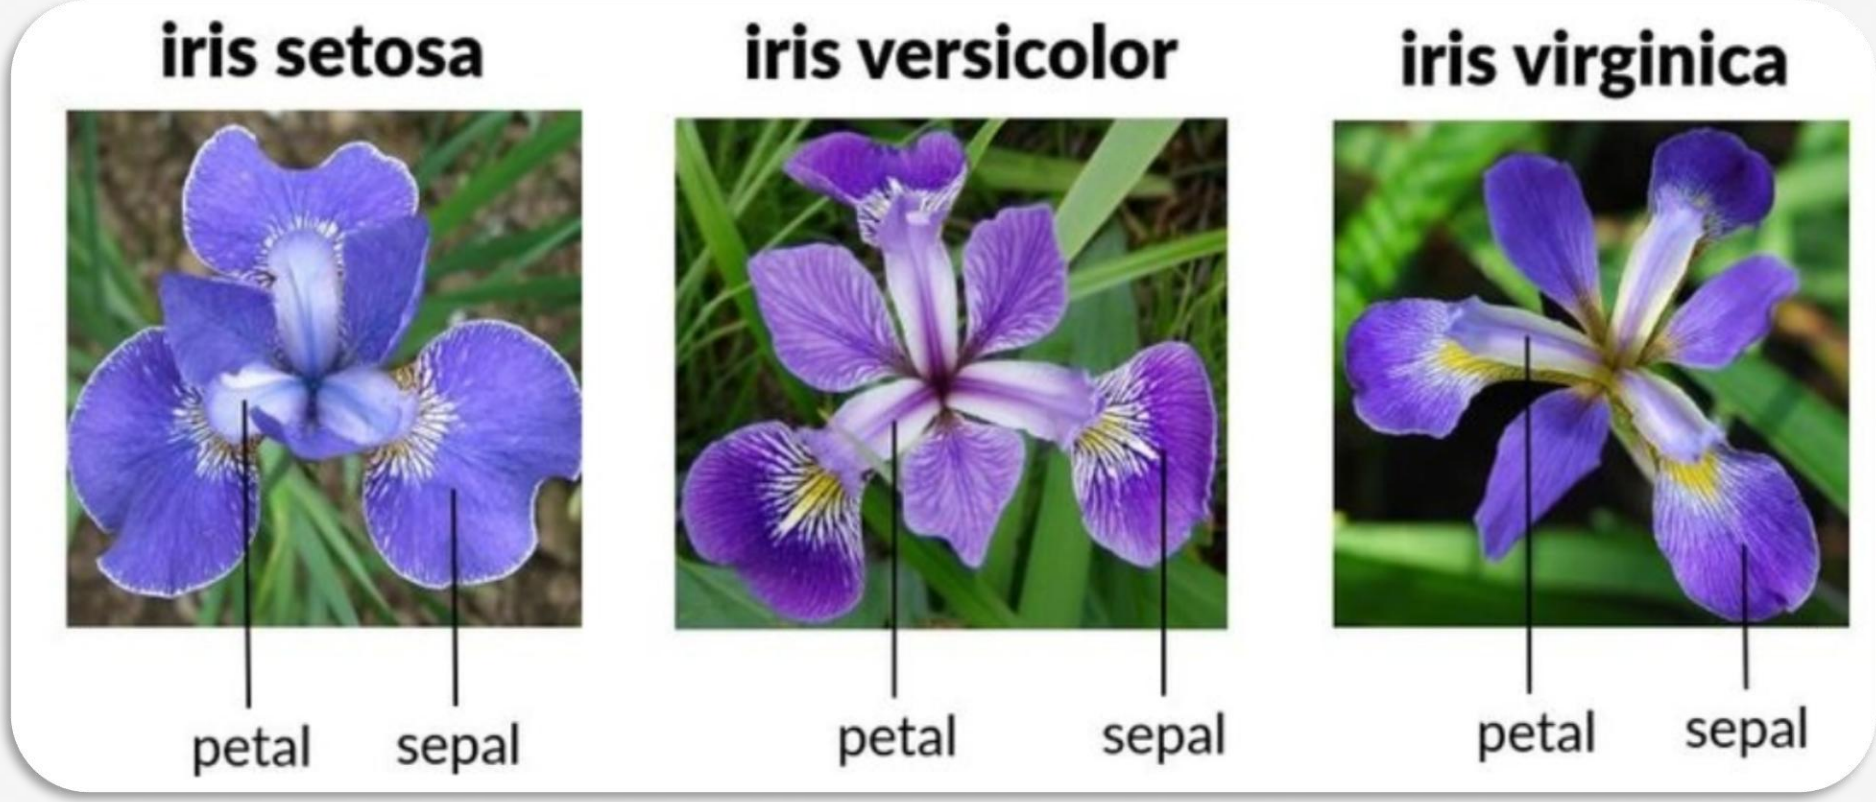

Vigilada Mineducación

➢ Ejemplo

Analizar el dataset ‘Iris’ usando Orange Data Mining.

- Medidas estadísticas
- Histogramas
- Diagramas de dispersión (scatter plots)

Vigilada Mineducación

➢Ejemplo

Analizar el dataset ‘Iris’ usando Orange Data Mining.

- Medidas estadísticas

Feature Statistics - Orange

	Name	Distribution	Mean	Mode	Median	Dispersion	Min.	Max.	Missing
N	sepal length		5.843	5.0	5.8	0.141	4.3	7.9	0 (0 %)
N	sepal width		3.054	3.0	3.0	0.142	2.0	4.4	0 (0 %)
N	petal width		1.199	0.2	1.3	0.635	0.1	2.5	0 (0 %)
N	petal length		3.759	1.5	4.350	0.468	1.0	6.9	0 (0 %)
C	iris			Iris-setosa		1.1			0 (0 %)

Iris-setosa Iris-versicolor Iris-virginica

Vigilada Mineducación

➢Ejemplo

Analizar el dataset ‘Iris’ usando Orange Data Mining.

- Histogramas

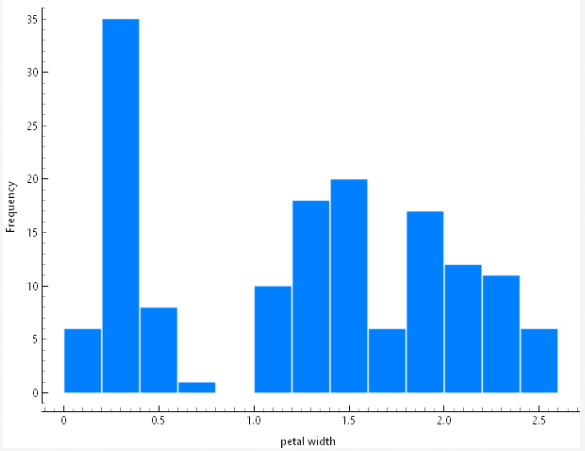

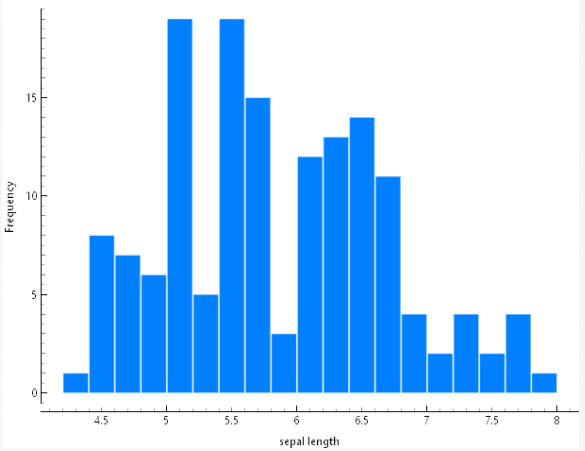

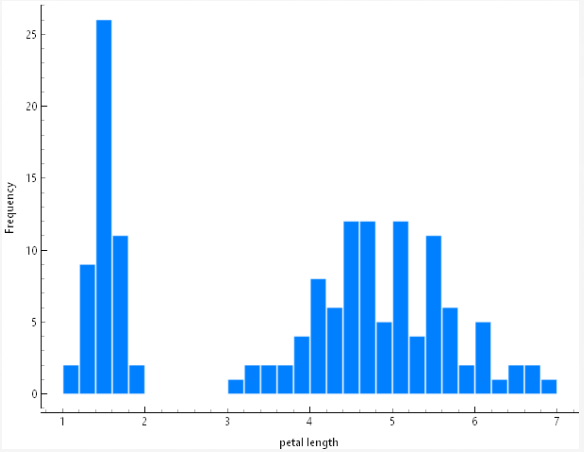

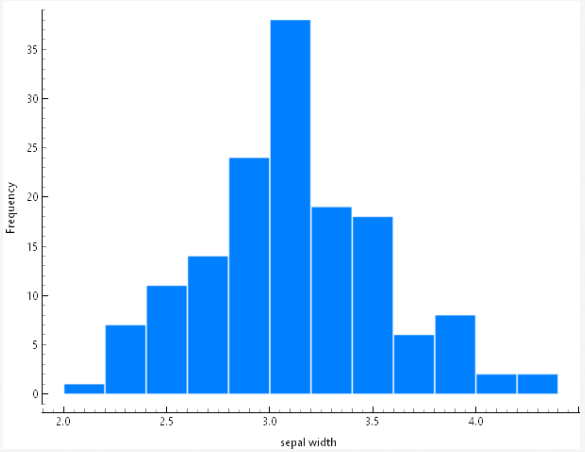

Vigilada Mineducación

➢Ejemplo

Analizar el dataset ‘Iris’ usando Orange Data Mining.

- Diagramas de dispersión (scatter plots)

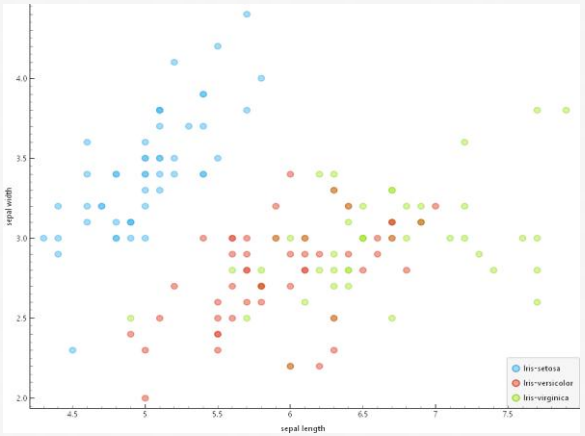

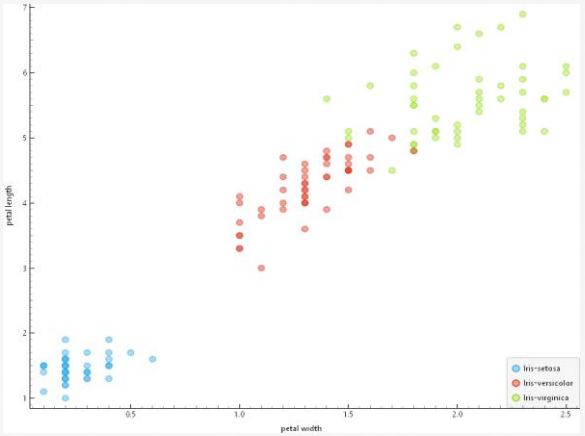

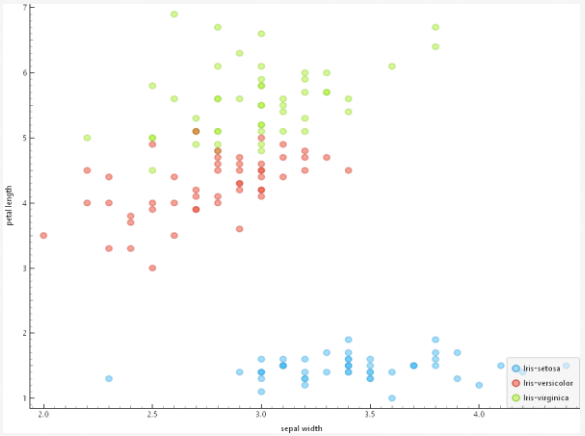

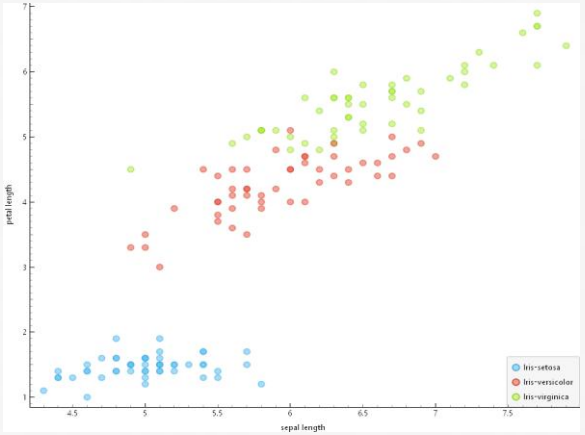

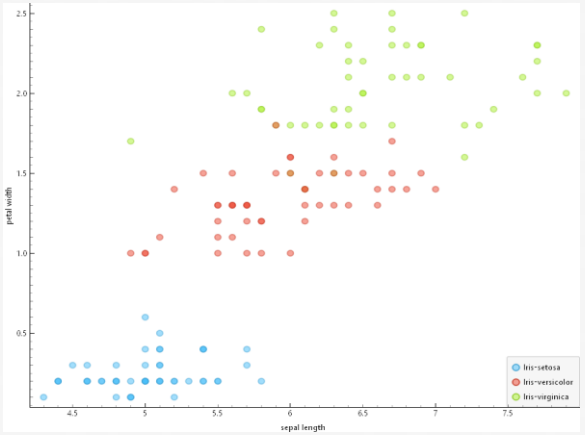

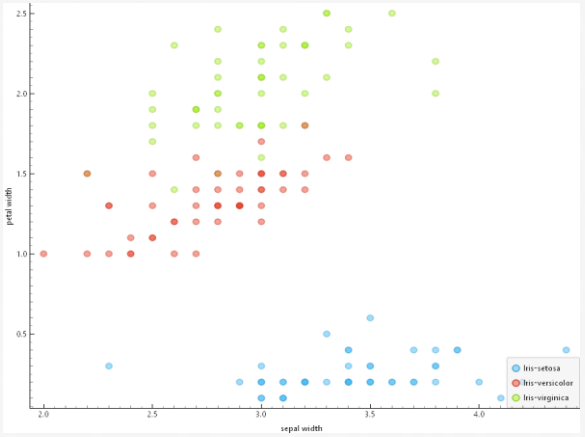

Vigilada Mineducación

➢Actividades en clase

Analizar el dataset ‘StudentsPerformance.csv’ usando Orange Data Mining.

Descripción del Dataset: Desempeño Estudiantil

Este dataset contiene información sobre el rendimiento académico de **1,000 estudiantes** en tres exámenes básicos, junto con diversos factores socioeconómicos y personales que pueden (o no) influir en sus resultados académicos.

Vigilada Mineducación

➢ Actividades en clase

Analizar el dataset ‘StudentsPerformance.csv’ usando Orange Data Mining.

	A	B	C	D	E	F	G	H
1	gender	race/ethnicity	parental level of education	lunch	test preparation course	math score	reading score	writing score
2	female	group B	bachelor's degree	standard	none	72	72	74
3	female	group C	some college	standard	completed	69	90	88
4	female	group B	master's degree	standard	none	90	95	93
5	male	group A	associate's degree	free/reduced	none	47	57	44
6	male	group C	some college	standard	none	76	78	75
7	female	group B	associate's degree	standard	none	71	83	78
8	female	group B	some college	standard	completed	88	95	92
9	male	group B	some college	free/reduced	none	40	43	39
10	male	group D	high school	free/reduced	completed	64	64	67
11	female	group B	high school	free/reduced	none	38	60	50
12	male	group C	associate's degree	standard	none	58	54	52
13	male	group D	associate's degree	standard	none	40	52	43
14	female	group B	high school	standard	none	65	81	73
15	male	group A	some college	standard	completed	78	72	70
16	female	group A	master's degree	standard	none	50	53	58
17	female	group C	some high school	standard	none	69	75	78
18	male	group C	high school	standard	none	88	89	86
19	female	group B	some high school	free/reduced	none	18	32	28
20	male	group C	master's degree	free/reduced	completed	46	42	46

Vigilada Mineducación

Variables del Dataset:

Factores Demográficos y Sociales:

- Género (gender).
- Raza/Etnicidad (race/ethnicity).
- Nivel Educativo de los Padres (parental level of education).
- Tipo de Almuerzo (lunch).
- Curso de Preparación (test preparation course).

Resultados Académicos (Variables Numéricas):

- Puntaje en Matemáticas (math score)
- Puntaje en Lectura (reading score).
- Puntaje en Escritura (writing score.

Vigilada Mineducación

➢Actividades en clase

Analizar el dataset ‘StudentsPerformance.csv’ usando Orange Data Mining.

- Obtener las medidas estadísticas, los histogramas y los diagramas de dispersión.
- Analizar la distribución de los datos, buscar correlaciones (relaciones entre variables).

Vigilada Mineducación

Institución Universitaria
Reacreditada en Alta Calidad

¡MUCHAS GRACIAS!

Material de apoyo usado para las clases de Introducción a la Ciencia de Datos

Elaborado por:
Esteban Gonzalez Valencia
estebangonzalez@itm.edu.co

Hacia una era de Universidad y Humanidad