1. IDENTIFICACIÓN DE LA GUÍA

Nombre de la guía:	Taller: Limpieza de un dataset
Código de la guía (No.):	*001*
Taller(es) o Laboratorio(s) aplicable(s):	
Tiempo de trabajo práctico estimado:	6 horas
Asignatura(s) aplicable(s):	Introducción a la ciencia de datos
Programa(s) Académico(s) / Facultad(es):	Ingeniería Electrónica

COMPETENCIAS	CONTENIDO TEMÁTICO	INDICADOR DE LOGRO
C3: Capacidad para desarrollar y realizar experimentos adecuados, analizar e interpretar datos, y utilizar el criterio de ingeniería para extraer conclusiones. C5: Capacidad para reconocer responsabilidades profesionales en situaciones de ingeniería y emitir juicios fundamentados al analizar e interpretar datos	Identificación de tipos de datos por columna e inspección inicial de datasets estructurados. Criterios para la imputación de datos (media, mediana, moda) frente a la eliminación de registros o columnas. Análisis de matrices de correlación y mapas de calor (*heatmaps*) para la selección de variables.	Realiza la carga de diferentes bases de datos, limpia los registros y organiza la información de manera coherente. Describe estadísticamente una base de datos e identifica los requerimientos necesarios para el desarrollo de un algoritmo de limpieza. Argumenta la solución implementada y las decisiones de diseño basadas en la relación y relevancia de los datos

2. FUNDAMENTO TEÓRICO

En la práctica de la Ciencia de Datos, el análisis exploratorio y la limpieza de información constituyen la etapa crítica para garantizar la validez de cualquier modelo predictivo o descriptivo posterior. En el entorno profesional, los datos rara vez se presentan en formatos óptimos; por ello, el ingeniero debe poseer la capacidad de inspeccionar exhaustivamente la estructura de un dataset, identificando tipos de variables, registros duplicados y vacíos de información que puedan sesgar los resultados. Esta competencia permite que el criterio de ingeniería aplicado para extraer conclusiones se sustente en datos íntegros, organizados y técnicamente validados.

El tratamiento de inconsistencias, como los datos faltantes, requiere un balance ético y técnico entre el rigor estadístico y la lógica del dominio del problema. El uso de técnicas de imputación basadas en medidas de tendencia central (media, mediana o moda) permite conservar la volumetría de la muestra, aunque el profesional debe evaluar críticamente si la naturaleza del dato exige la corrección o la eliminación definitiva de registros para no comprometer la calidad de la información. La implementación de estas soluciones mediante librerías especializadas en Python, como Pandas y Seaborn, proporciona un ecosistema robusto para transformar datos crudos en activos de información listos para el análisis de patrones y la toma de decisiones informadas. Asimismo, el estudio de la correlación permite al profesional cuantificar la fuerza y dirección de las relaciones entre variables numéricas, facilitando la identificación de redundancias o dependencias críticas antes de proceder a etapas de modelado o predicción.

3. OBJETIVOS

- Identificar los tipos de datos y la estructura general de un conjunto de datos estructurado mediante una inspección inicial técnica.
- Ejecutar acciones de limpieza de datos, incluyendo la eliminación de registros duplicados y la normalización de nombres de variables para mejorar la organización de la información.
- Aplicar métodos de imputación de valores faltantes utilizando medidas de tendencia central (media, mediana o moda) según la naturaleza de la variable analizada.
- Analizar y justificar decisiones de ingeniería sobre el tratamiento de datos incompletos, evaluando la conveniencia de imputar valores frente a la eliminación de registros o columnas.
- Cuantificar y visualizar el grado de relación entre las variables físicas del dataset mediante el cálculo de la matriz de correlación y la generación de mapas de calor

4. RECURSOS REQUERIDOS

Los elementos requeridos para realizar el taller son:

- Computador personal con internet.
- Acceso a software tipo Visual Studio Code, Google Colab, Kagle Notebooks, entre otros.
- Material de estudio entregado en clase (Notebooks).

5. ASPECTOS DE SEGURIDAD

No aplica.

6. PROCEDIMIENTO O METODOLOGÍA PARA EL DESARROLLO

6.1. Para ese taller, usaremos el dataset "Penguins". Utilizaremos la librería seaborn de Python para cargar el dataset directamente en un DataFrame de pandas. Para cargar el dataset, pegar el siguiente código en Colab:

```
# Importar las librerías necesarias
import pandas as pd
import seaborn as sns

# Cargar y mostrar el dataset 'penguins'
df = sns.load_dataset('penguins')
df
```

A continuación, encontrarán la descripción cada una de las Columnas que componen este dataset:

- **species**: La especie del pingüino, tiene tres valores posibles: 'Adelie', 'Chinstrap' y 'Gentoo'. En este análisis, esta será la variable objetivo (la que nos gustaría predecir).
- **island**: La isla en el archipiélago Palmer (Antártida) donde se observó al pingüino. Tiene tres valores: 'Torgersen', 'Biscoe' y 'Dream'.
- **bill_length_mm**: La longitud del pico (culmen) del pingüino en milímetros.

- **bill_depth_mm**: La profundidad (altura) del pico del pingüino en milímetros.
- **flipper_length_mm**: La longitud de la aleta del pingüino en milímetros.
- **body_mass_g**: La masa corporal (peso) del pingüino en gramos.

6.2. Inspeccionar el dataset

a. Qué tipo de datos tiene cada columna

b. Establezca cuántas columnas tienen valores faltantes y cuántos valores faltan en cada una

c. Cuantos registros duplicados tiene el dataset.

6.3. Limpieza de datos.

a. Elimine los registros duplicados

b. Renombre las columnas usando nombres en español

c. Imputar los datos faltantes de longitud, profundidad del pico, masa corporal y longitud de aleta. ¿cuál es la mejor forma de imputar cada columna en particular (media, mediana, moda)?

NOTA: Una mejor alternativa consiste en eliminar las filas con datos faltantes, sin embargo, en este taller trabajaremos imputando los datos con fines pedagógicos.

d. Imputar los datos faltantes de sexo. ¿cuál es la mejor forma de imputar esta columna en particular (media, mediana, moda)? Justifique técnicamente si para la columna 'sexo' utilizó la moda o la media, y por qué".

e. Analice si fue en realidad es conveniente imputar los datos faltantes en este dataset, o si en su defecto ¿es mejor eliminar las columnas? ¿o eliminar las filas?

f. Cambiar las variables categóricas sexo a variables numéricas.

g. Cambiar las variables categóricas isla, usando el prefijo 'Isla', convirtiéndolo en tres columnas booleanas.

NOTA: Para los análisis que vamos a hacer, no se recomienda convertir la variable especie, ya que es la variable objetivo.

h. Convertir las datos de columna de masa corporal que están en gramos a kilogramos.

6.4. Distribución de Variables Numéricas

a. Genere un histograma para la variable masa_corporal_kg.

b. Observe la forma del histograma. ¿Los datos siguen una distribución aproximadamente normal (campana de Gauss) o presentan algún sesgo (cola) hacia la derecha o izquierda? Justifique su respuesta comparando la posición de la media y la mediana.

6.5. Comparación de Grupos

a. Construya un Gráfico de Violín que compare el largo_aleta_mm (eje Y) según la especie (eje X).

b. Análisis: ¿Cuál especie presenta, en promedio, las aletas más largas? Observe la "anchura" del violín en cada especie: ¿qué le indica esto sobre la concentración de los datos en comparación con las otras especies?

c. Complemente con un Boxplot de la misma variable e identifique si existen valores atípicos (outliers) en alguna de las especies.

6.6. Relación entre Variables

a. Cree un gráfico de dispersión (scatter plot) comparando el largo_pico_mm (eje X) frente a la profundidad_pico_mm (eje Y).

b. Diferencie los puntos por color según la variable especie.

c. ¿Se observan agrupaciones (clusters) claros por especie? ¿La relación entre el largo y la profundidad del pico parece ser lineal o no existe una correlación evidente?

6.7. Utilice un Boxplot para determinar si existe una diferencia significativa en la masa corporal entre machos y hembras".

6.8. ¿Cómo se distribuyen los pingüinos de la especie 'Adelie' entre las tres diferentes islas?

6.9. Utilice un gráfico de dispersión para analizar qué tan fuerte es la correlación entre la masa corporal y el largo de la aleta.

6.10. Matriz de correlación.

- **a.** Seleccione únicamente las variables numéricas del dataset (omitir las columnas de correspondiente a las islas).
- **b.** Calcule la matriz de correlación de Pearson utilizando el método .corr().
- **c.** Genere un mapa de calor (heatmap) con la librería Seaborn, incluyendo los valores numéricos de las celdas (annot=True) y configurando el rango de la escala de -1 a 1 (vmax=1, vmin=-1).
- **d.** Encuentre las correlaciones más fuertes y las correlaciones más débiles del dataset.
- **e.** Analice la correlación entre la variable sexo y las demás variables del dataset. ¿Que ve en común? En términos de la vida real, ¿qué significa?

7. PARÁMETROS PARA ELABORACIÓN DEL INFORME

No aplica

8. DISPOSICIÓN DE RESIDUOS

No aplica

9. BIBLIOGRAFÍA

[1] https://github.com/estebangonzalezITM/DataScience

[2] McKinney, W. (2022). Pandas: Powerful Python data analysis toolkit.

[3] Healy, K. (2019). Data visualization: A practical introduction

Elaborado por:	*Esteban Gonzalez Valencia*
Revisado por:	*Comité de Inteligencia Computacional*
Versión:	*1*
Fecha:	*Abril de 2026*