Institución Universitaria
Reacreditada en Alta Calidad

# APRENDIZAJE AUTOMÁTICO SUPERVISADO

## CLASIFICACIÓN

INTRODUCCIÓN A LA CIENCIA DE DATOS

530202018

www.itm.edu.co

Vigilado Mineducación

# CONTEXTO DE LA INTELIGENCIA ARTIFICIAL

"La IA está transformando rápidamente la vida y los negocios, mejorando la forma en que diagnosticamos y tratamos las enfermedades, cultivamos nuestros alimentos, fabricamos y entregamos nuevos productos, administramos nuestras finanzas, alimentamos nuestros hogares y viajamos del punto A al punto B."

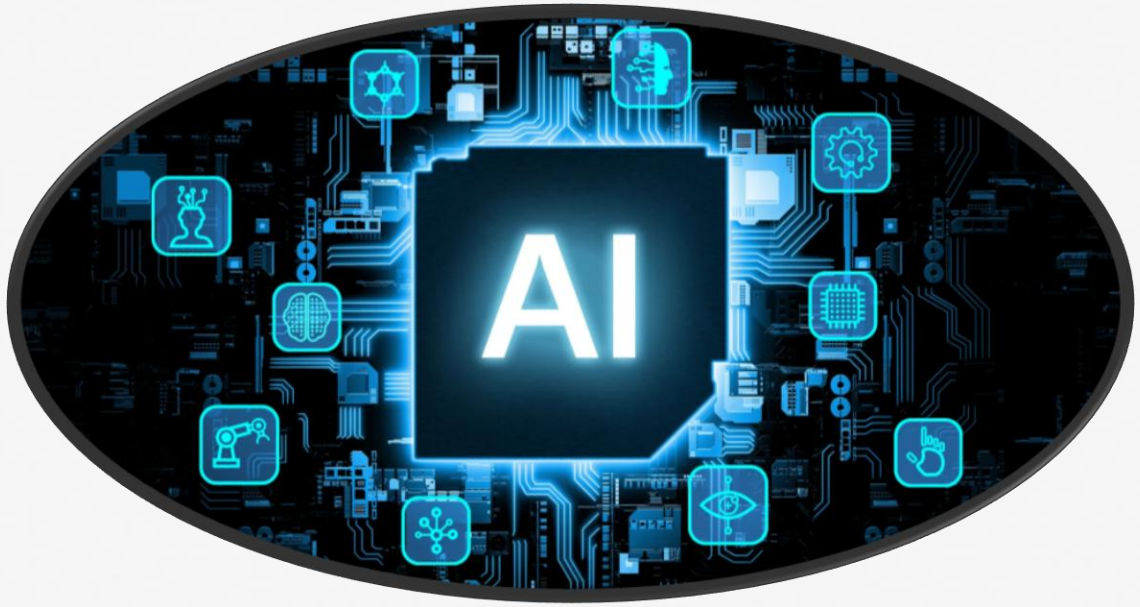


Vigilada Mineducación

https://www.whitehouse.gov/wp-content/uploads/2018/05/Summary-Report-of-White-House-AI-Summit.pdf
https://msmk.university/inteligencia-artificial

# CONTEXTO DE LA INTELIGENCIA ARTIFICIAL

"Los expertos prevén que continuarán los rápidos progresos en el campo de la inteligencia artificial especializada. Aunque es muy poco probable que las máquinas exhiban una inteligencia ampliamente aplicable comparable o superior a la de los humanos en los próximos 20 años, es de esperar que las máquinas alcancen y superen el rendimiento humano en más y más tareas".

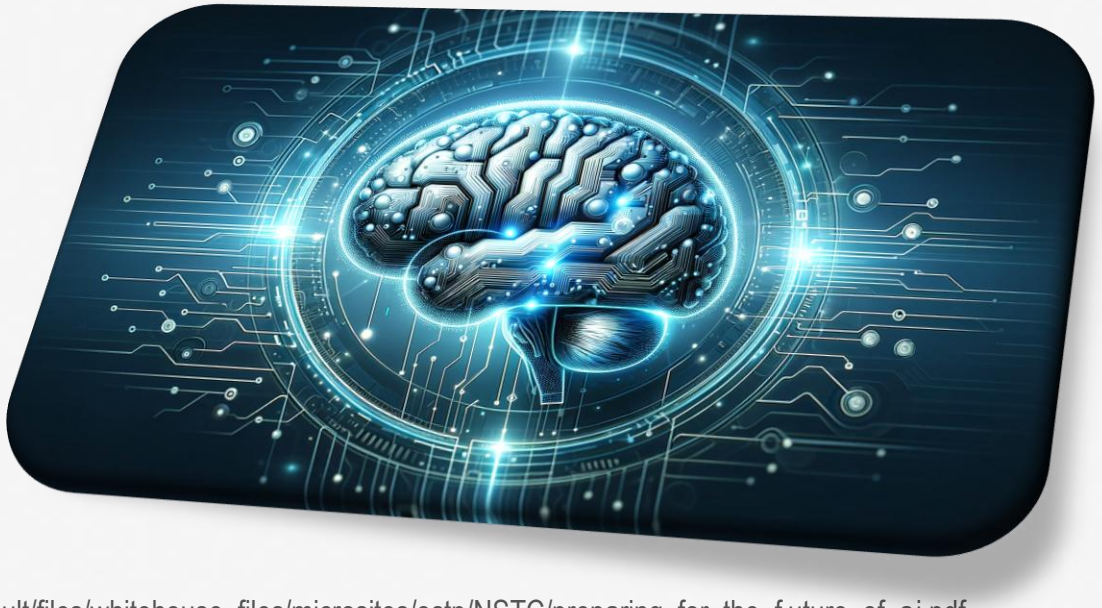

Vigilada Mineducación

https://obamawhitehouse.archives.gov/sites/default/files/whitehouse_files/microsites/ostp/NSTC/preparing_for_the_f uture_of_ai.pdf
https://delatorre.ai/introduccion-a-la-ia-desentranando-los-fundamentos-de-la-inteligencia-artificial

# CONTEXTO DE LA INTELIGENCIA ARTIFICIAL

En los últimos años, la mayoría de las aplicaciones exitosas de la IA al mundo real provienen de una de sus disciplinas conocía como el Aprendizaje Automático o Machine Learning.

"El aprendizaje automático es un subdominio de la IA que proporciona a los sistemas la capacidad de aprender y mejorar automáticamente a partir de la experiencia sin ser explícitamente programados para ello. Se basa en la hipótesis subyacente de crear el modelo y trata de mejorarlo ajustando más datos en el modelo a lo largo del tiempo."

Vigilada Mineducación

Koza, John & Bennett III, Forrest & Andre, David & Keane, Martin. (1998). Automated Design Of Both The Topology And Sizing Of Analog Electrical Circuits Using Genetic Programming.

# ¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

El aprendizaje automático puede entenderse como la intersección entre la ciencia de datos y la ingeniería de software.

El objetivo del aprendizaje automático es usar datos para crear un modelo predictivo que se pueda incorporar a una aplicación o servicio de software. Para lograr este objetivo, es necesaria la colaboración entre científicos de datos que exploran y preparan los datos antes de usarlos para entrenar un modelo de Machine Learning y los desarrolladores de software que integran los modelos en aplicaciones en las que se usan para predecir nuevos valores de datos (un proceso conocido como inferencia).

Vigilada Mineducación

# ¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

## Hitos del aprendizaje automático:

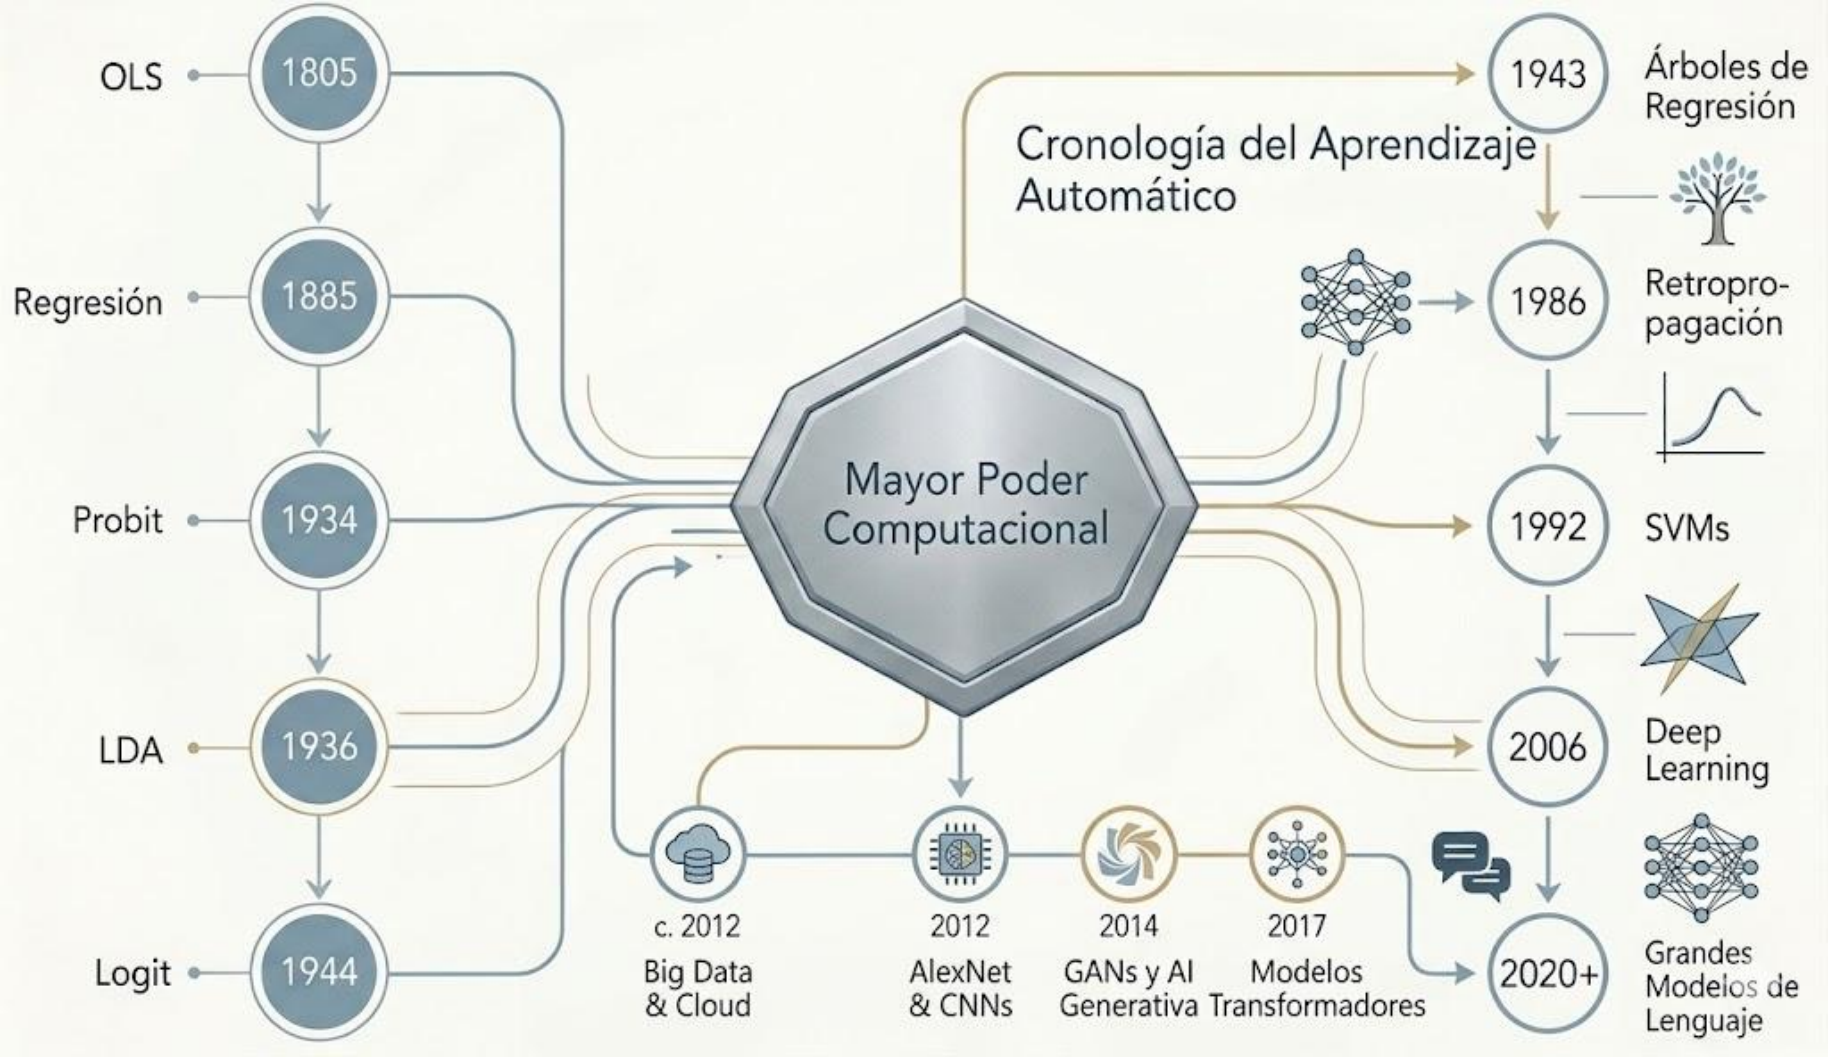


Vigilada Mineducación

# ¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

## Tipos de aprendizaje automático:

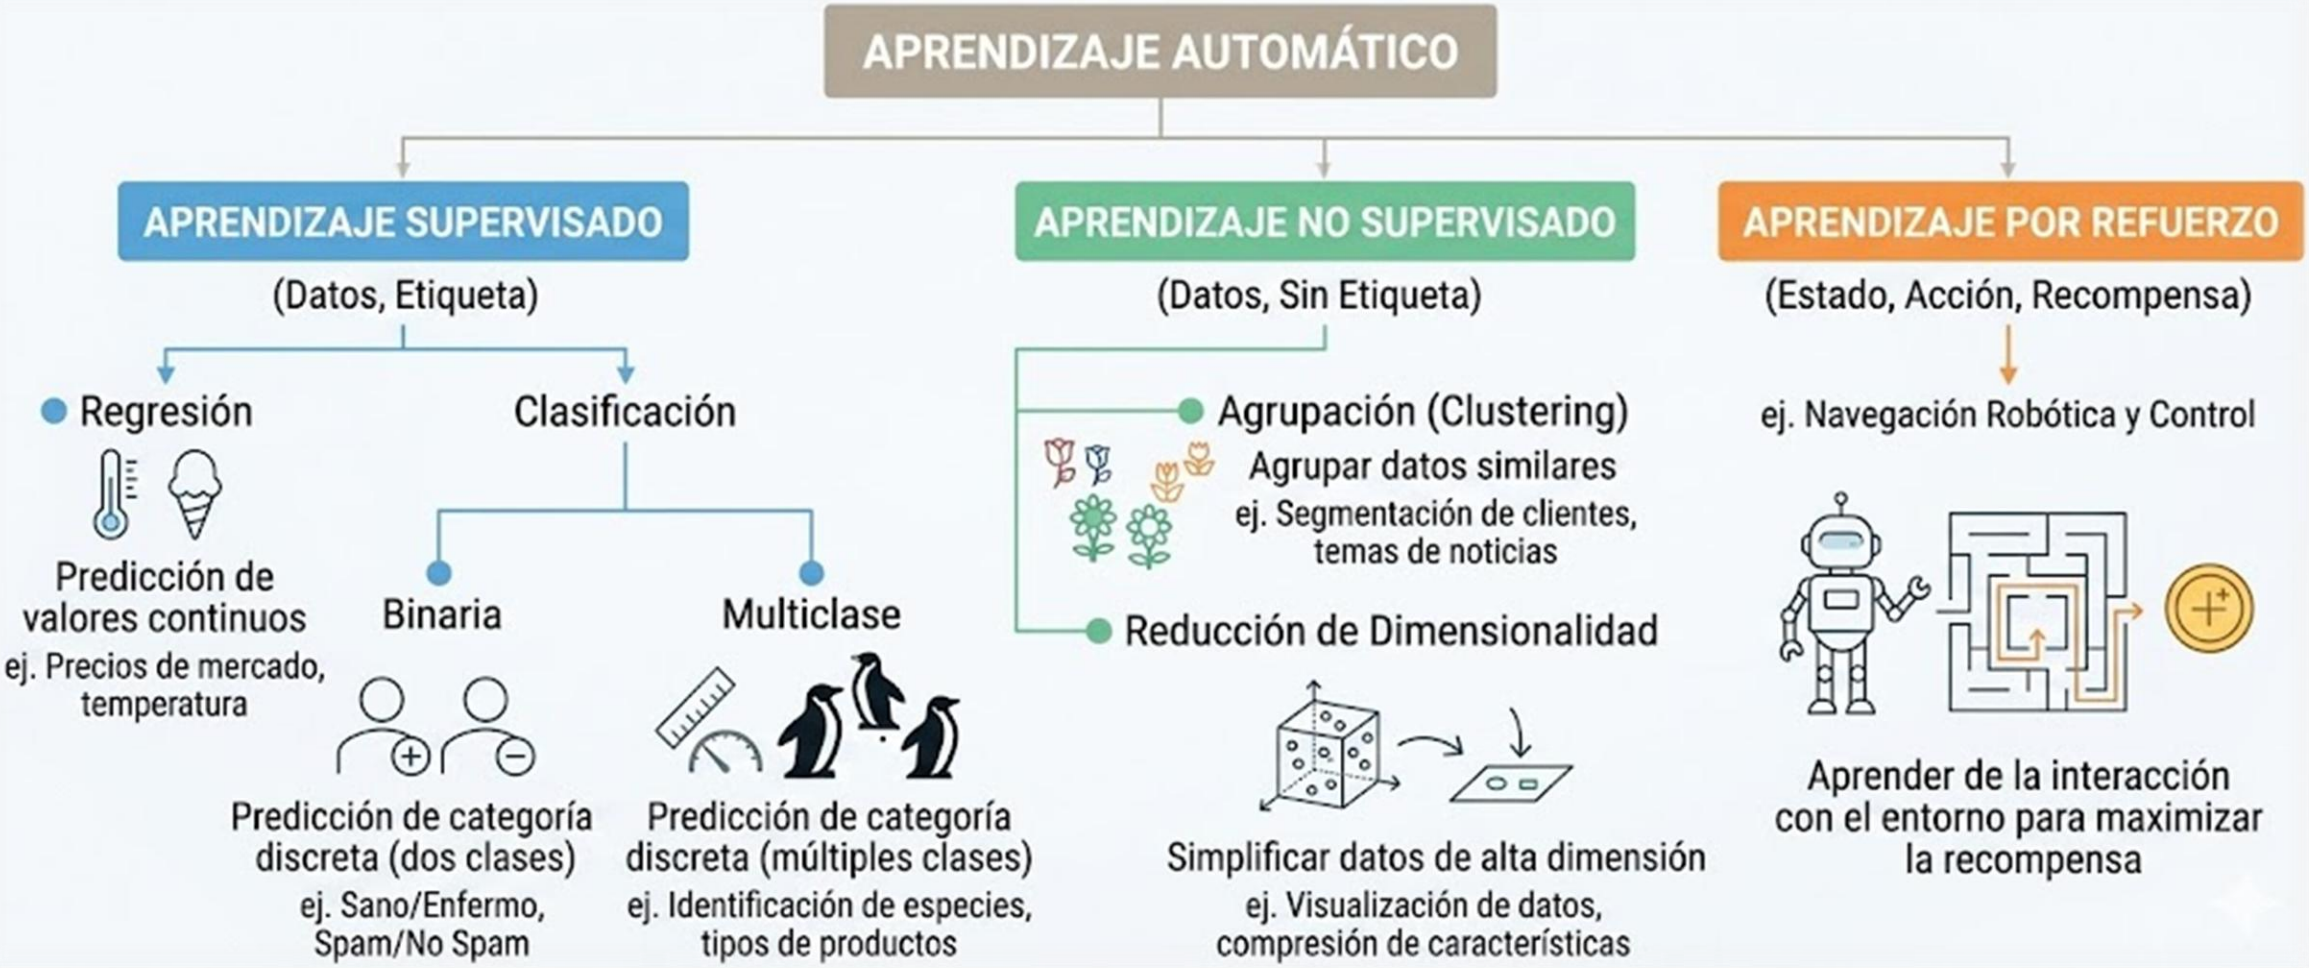


Vigilada Mineducación

# ¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

## Tipos de aprendizaje automático:

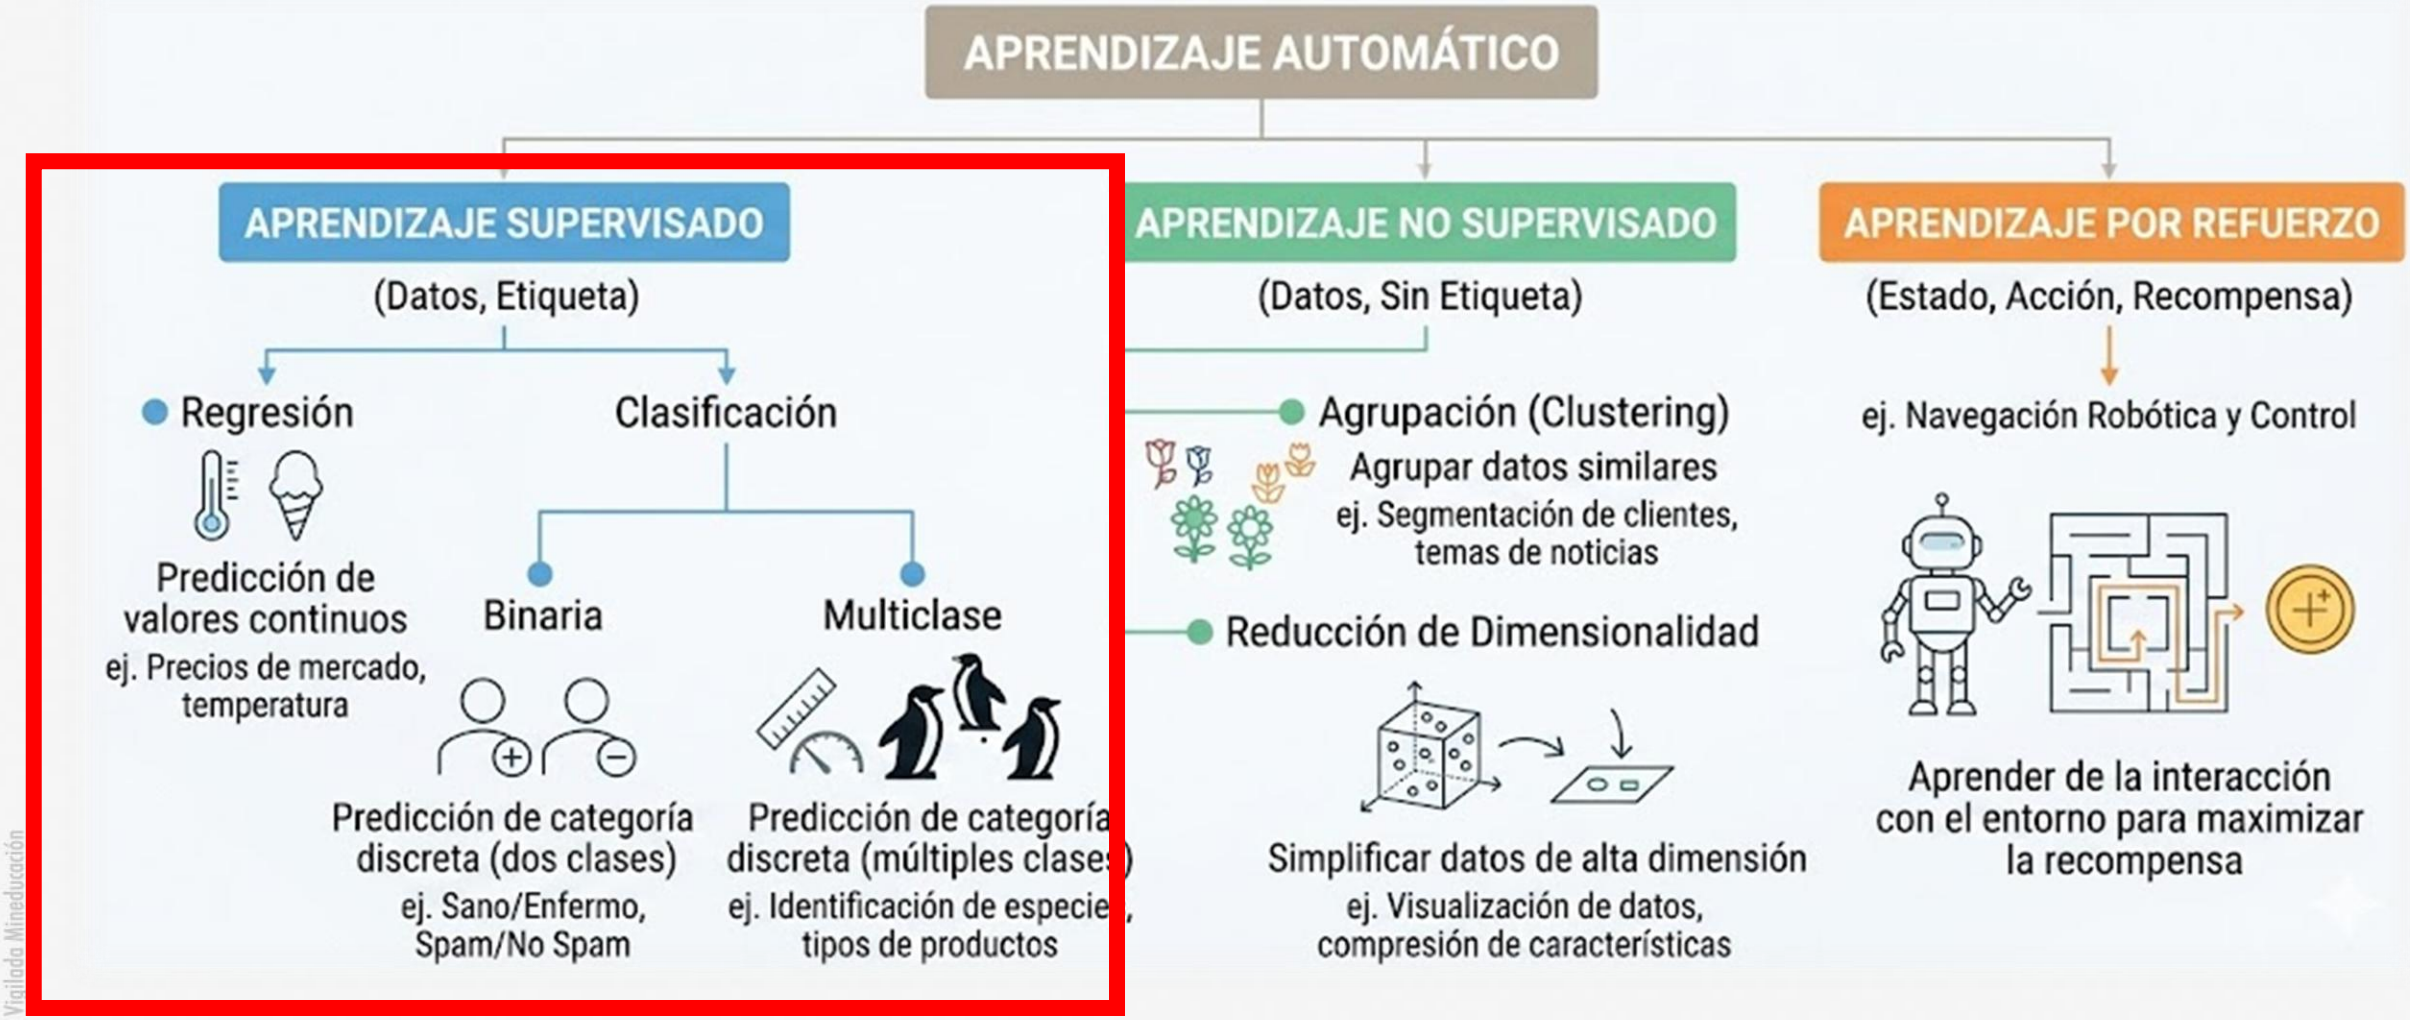


Vigilada Mineducación

# APRENDIZAJE AUTOMÁTICO SUPERVISADO

El aprendizaje automático supervisado es un término general para los algoritmos de aprendizaje automático en los que los datos de entrenamiento incluyen valores de características y valores de etiqueta conocidos.

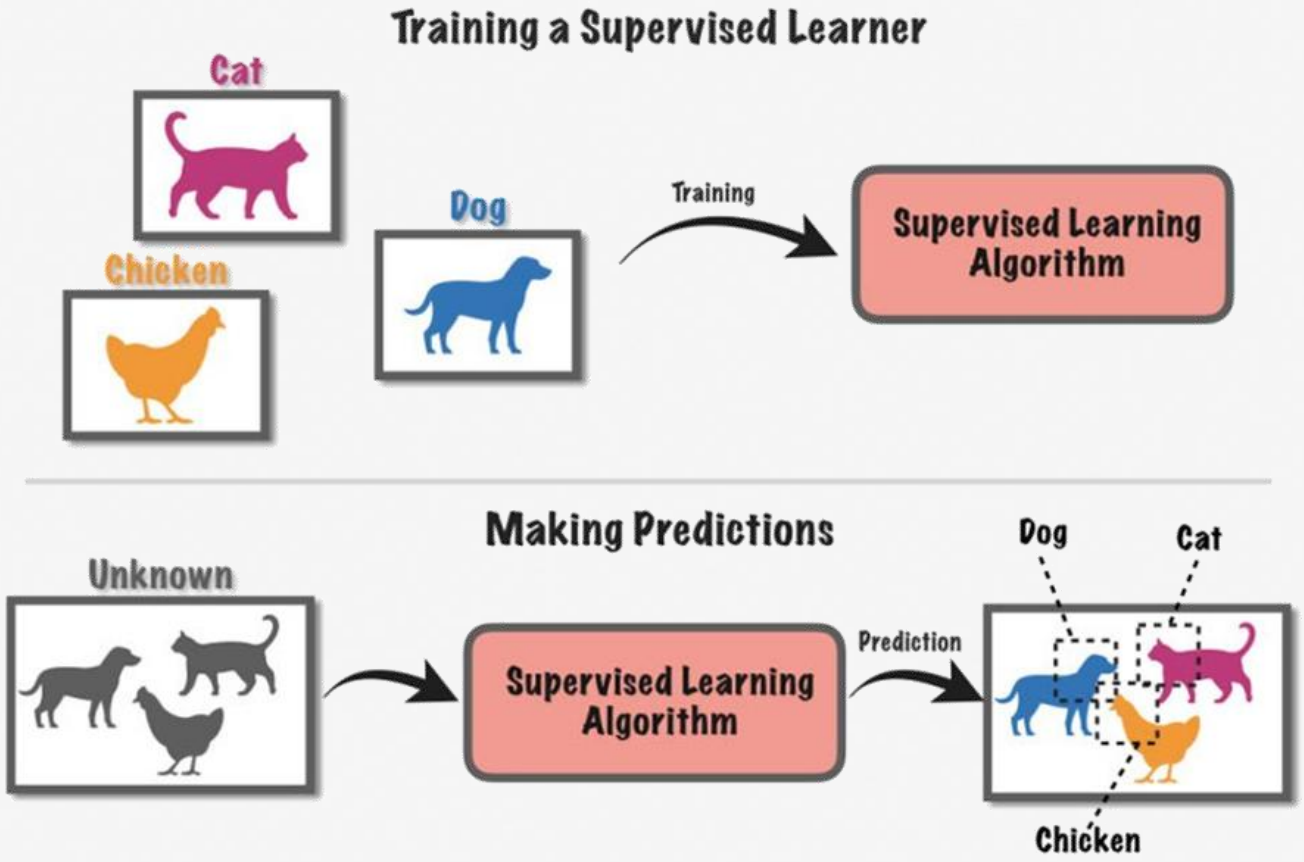


Vigilada Mineducación

# APRENDIZAJE AUTOMÁTICO COMO UNA FUNCIÓN

1. Los datos de entrenamiento constan de observaciones pasadas. En general, las observaciones incluyen los atributos observados, y el valor conocido de lo que se quiere entrenar un modelo de predicción (conocido como la etiqueta).

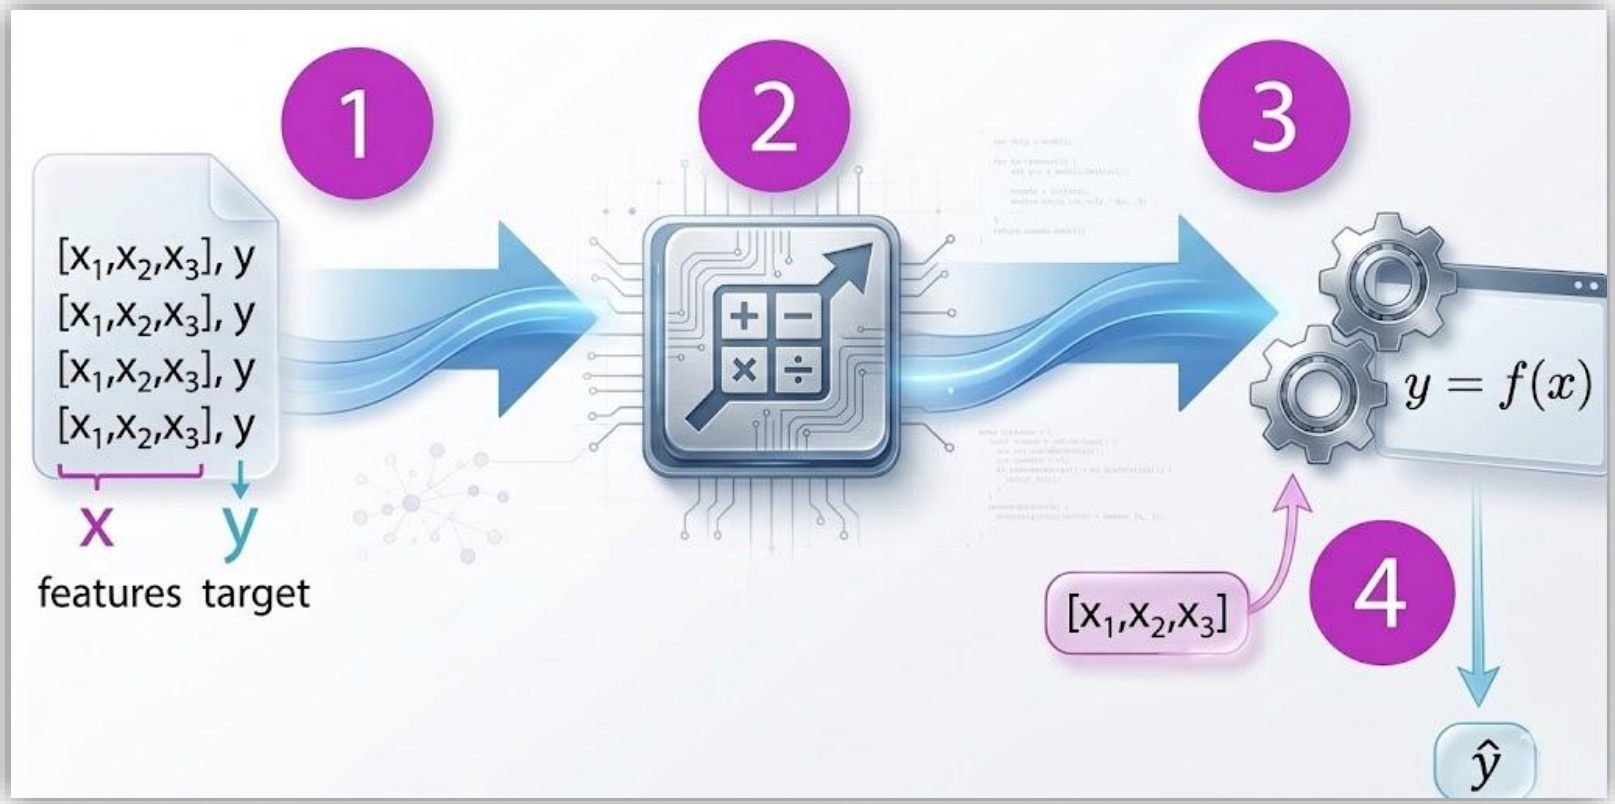


Vigilada Mineducación

# APRENDIZAJE AUTOMÁTICO COMO UNA FUNCIÓN

**2.** Se aplica un algoritmo a los datos para determinar una relación entre las características y las etiquetas, como un cálculo que puede realizarse sobre $x$ para calcular $y$.

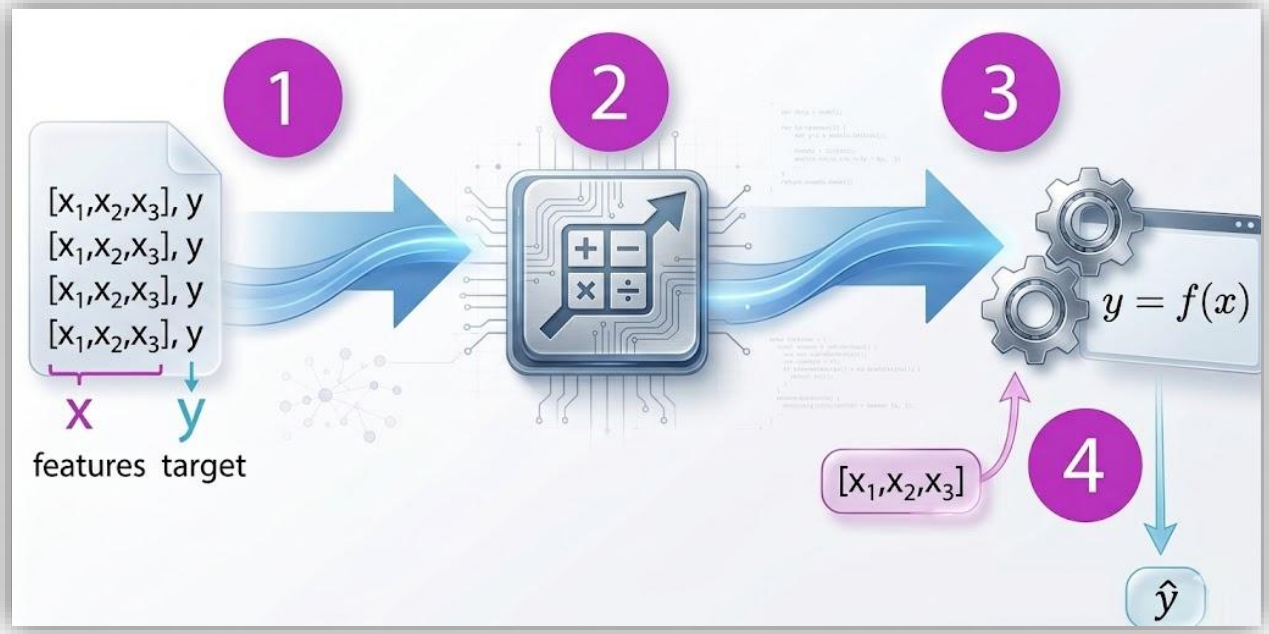


El algoritmo escogido depende de cada problema, pero el principio es ajustar una función a los datos en los que los valores de las características puedan usarse para calcular la etiqueta.

Vigilada Mineducación

# APRENDIZAJE AUTOMÁTICO COMO UNA FUNCIÓN

**3.** El resultado del algoritmo es un modelo que encapsula el cálculo derivado por el algoritmo como una función, tal que:

$$y = f(x)$$

Este proceso se conoce como entrenamiento.

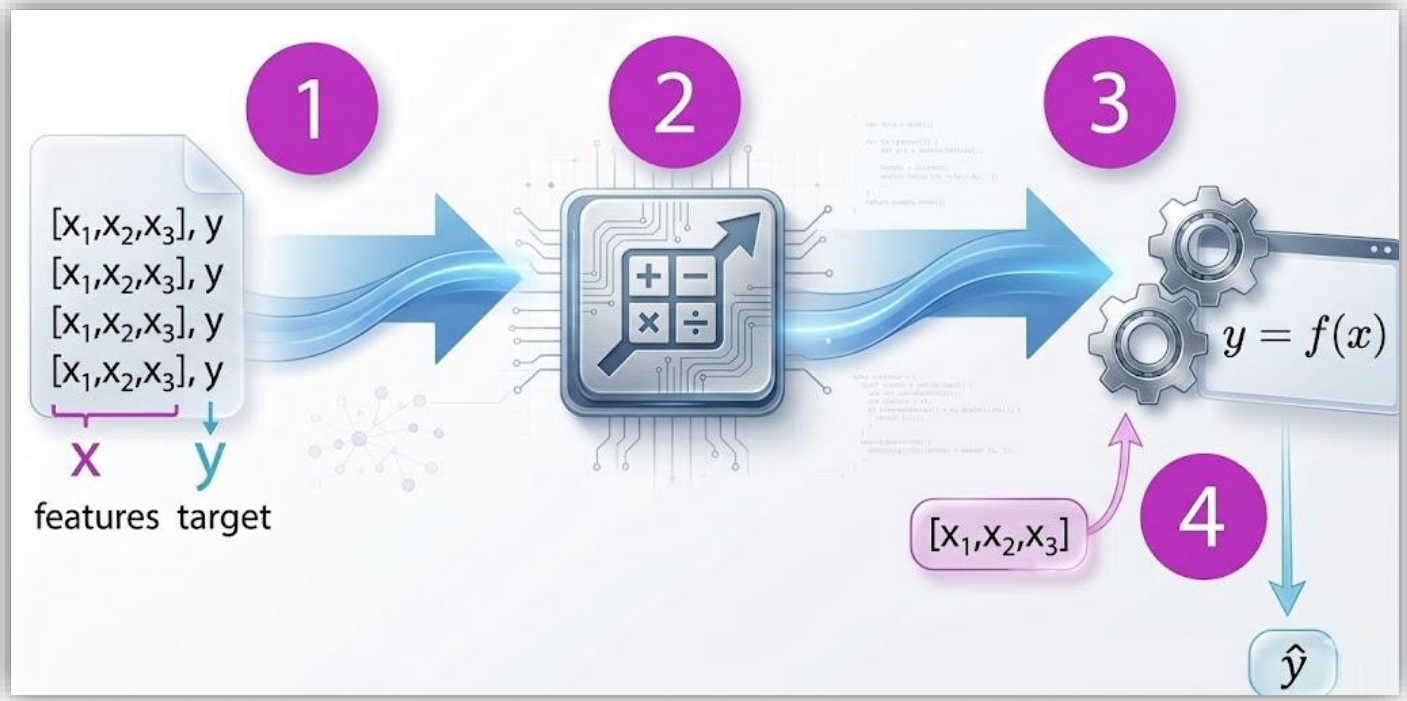


Vigilada Mineducación

# 4. Ahora el modelo está entrenado.

El modelo recibe un conjunto de valores de características y entrega como salida una predicción de la etiqueta correspondiente.

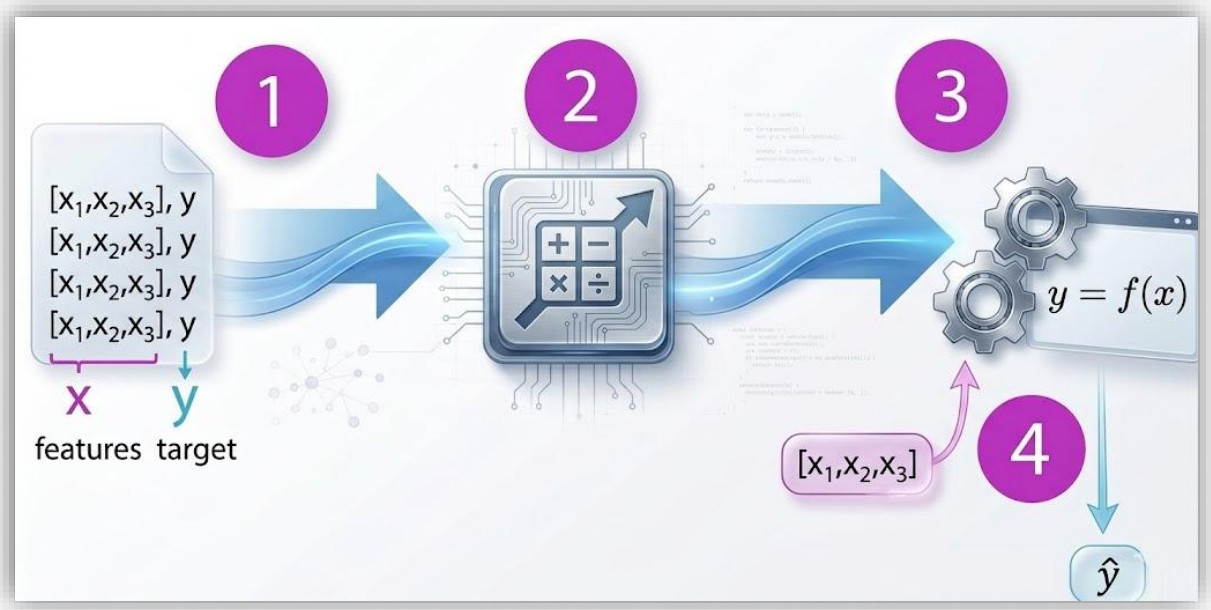


La salida del modelo es una predicción calculada por la función y no un valor observado, que a menudo se muestra como $\hat{y}$.

Vigilada Mineducación

## REGRESIÓN

Es una forma de aprendizaje automático supervisado en la que la etiqueta predicha por el modelo es un valor numérico. Algunos ejemplos:

- El número de helados vendidos en un día, en función de la temperatura, la precipitación y la velocidad del viento.

Vigilada Mineducación

## REGRESIÓN

Es una forma de aprendizaje automático supervisado en la que la etiqueta predicha por el modelo es un valor numérico. Algunos ejemplos:

- El número de helados vendidos en un día, en función de la temperatura, la precipitación y la velocidad del viento.
- El precio de venta de una propiedad en función de su tamaño, el número de habitaciones que tiene, antigüedad y los parámetros socioeconómicos de su ubicación.

Vigilada Mineducación

## REGRESIÓN

Es una forma de aprendizaje automático supervisado en la que la etiqueta predicha por el modelo es un valor numérico. Algunos ejemplos:

- El número de helados vendidos en un día, en función de la temperatura, la precipitación y la velocidad del viento.
- El precio de venta de una propiedad en función de su tamaño, el número de habitaciones que tiene, antigüedad y los parámetros socioeconómicos de su ubicación.
- La eficiencia de combustible de un auto (en km/galón) en función del tamaño de su motor, peso, anchura, altura, longitud y antigüedad.

Vigilada Mineducación

# REGRESIÓN

| | longitude | latitude | housing_median_age | total_rooms | total_bedrooms | population | households | median_income | median_house_value |
|---|---|---|---|---|---|---|---|---|---|
| **0** | -114.31 | 34.19 | 15.0 | 5612.0 | 1283.0 | 1015.0 | 472.0 | 1.4936 | 66900.0 |
| **1** | -114.47 | 34.40 | 19.0 | 7650.0 | 1901.0 | 1129.0 | 463.0 | 1.8200 | 80100.0 |
| **2** | -114.56 | 33.69 | 17.0 | 720.0 | 174.0 | 333.0 | 117.0 | 1.6509 | 85700.0 |
| **3** | -114.57 | 33.64 | 14.0 | 1501.0 | 337.0 | 515.0 | 226.0 | 3.1917 | 73400.0 |
| **4** | -114.57 | 33.57 | 20.0 | 1454.0 | 326.0 | 624.0 | 262.0 | 1.9250 | 65500.0 |

Vigilada Mineducación

# REGRESIÓN

Características (Features)

| | longitude | latitude | housing_median_age | total_rooms | total_bedrooms | population | households | median_income | median_house_value |
|---|---|---|---|---|---|---|---|---|---|
| 0 | -114.31 | 34.19 | 15.0 | 5612.0 | 1283.0 | 1015.0 | 472.0 | 1.4936 | 66900.0 |
| 1 | -114.47 | 34.40 | 19.0 | 7650.0 | 1901.0 | 1129.0 | 463.0 | 1.8200 | 80100.0 |
| 2 | -114.56 | 33.69 | 17.0 | 720.0 | 174.0 | 333.0 | 117.0 | 1.6509 | 85700.0 |
| 3 | -114.57 | 33.64 | 14.0 | 1501.0 | 337.0 | 515.0 | 226.0 | 3.1917 | 73400.0 |
| 4 | -114.57 | 33.57 | 20.0 | 1454.0 | 326.0 | 624.0 | 262.0 | 1.9250 | 65500.0 |

Etiqueta (label)

Vigilada Mineducación

# REGRESIÓN

| | longitude | latitude |
|---|---|---|
| 0 | -114.31 | 34.19 |
| 1 | -114.47 | 34.40 |
| 2 | -114.56 | 33.69 |
| 3 | -114.57 | 33.64 |
| 4 | -114.57 | 33.57 |

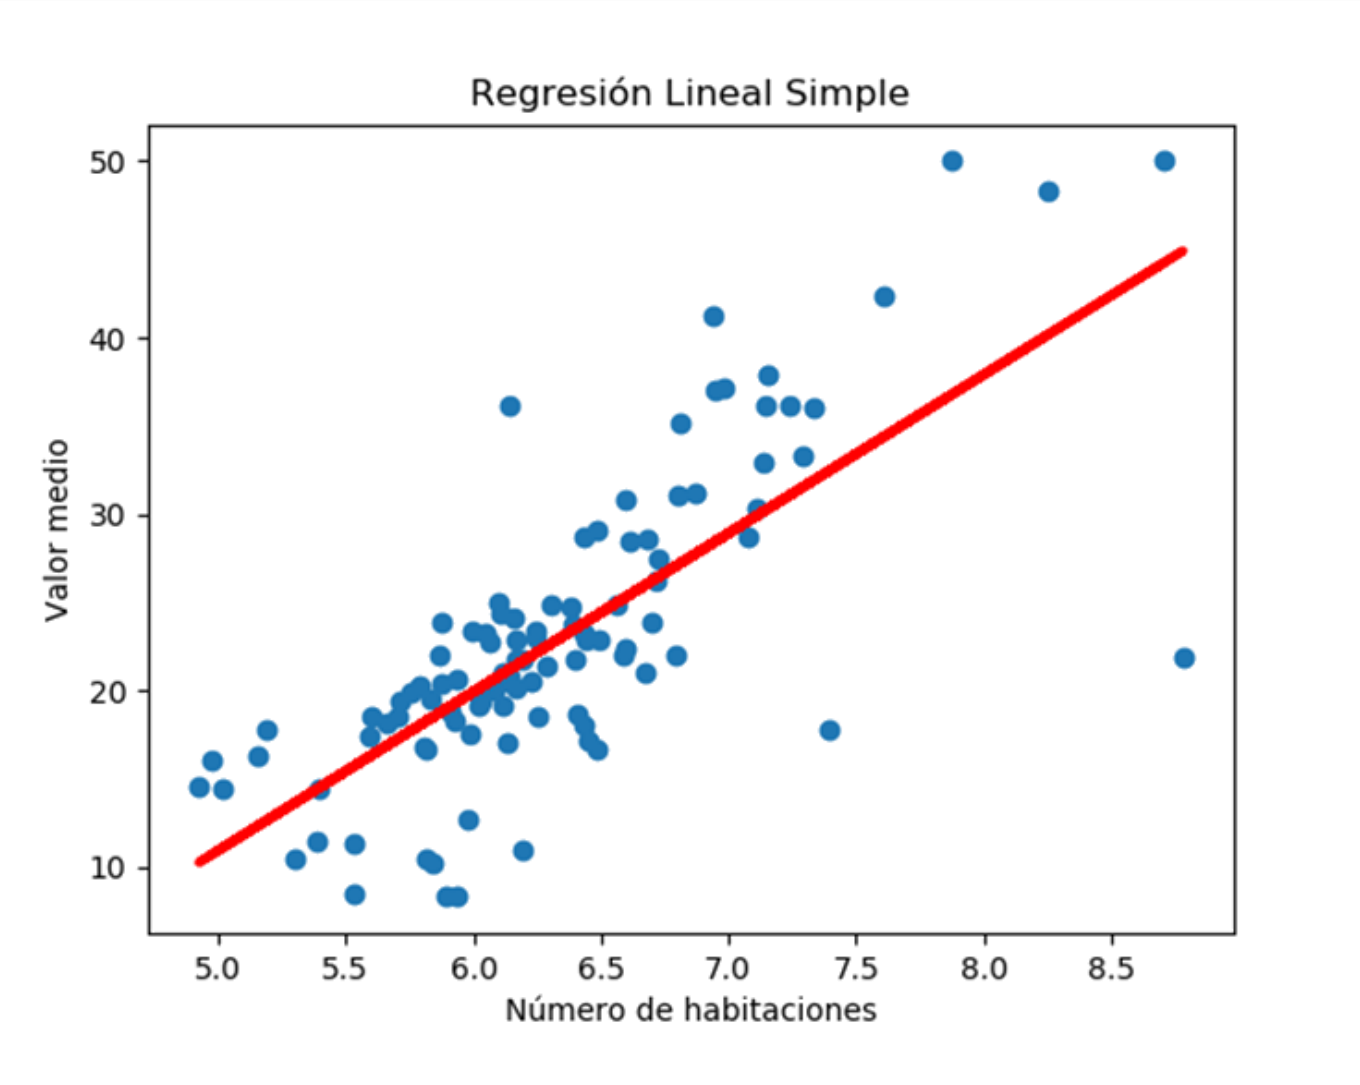


| median_income | median_house_value |
|---|---|
| 1.4936 | 66900.0 |
| 1.8200 | 80100.0 |
| 1.6509 | 85700.0 |
| 3.1917 | 73400.0 |
| 1.9250 | 65500.0 |

Etiqueta (label)

Vigilada Mineducación

## REGRESIÓN

Aunque una regresión lineal simple es útil para entender la relación entre dos variables, los problemas del mundo real suelen ser multidimensionales.

En este ejemplo, el valor de la vivienda depende diversos factores (features), lo que hace necesario el uso de modelos de **Aprendizaje Supervisado Multivariado**.

Vigilada Mineducación

## CLASIFICACIÓN BINARIA

En la clasificación binaria, la etiqueta determina si el elemento observado es (o no) una instancia de una clase específica. O bien, los modelos de clasificación binaria predicen uno de dos resultados mutuamente excluyentes.

Vigilada Mineducación

## CLASIFICACIÓN BINARIA

En la clasificación binaria, la etiqueta determina si el elemento observado es (o no) una instancia de una clase específica. O bien, los modelos de clasificación binaria predicen uno de dos resultados mutuamente excluyentes. Por ejemplo:

- Si un paciente corre riesgo de padecer diabetes en función de parámetros clínicos como el peso, la edad, el nivel de glucosa, etc.

Vigilada Mineducación

## CLASIFICACIÓN BINARIA

En la clasificación binaria, la etiqueta determina si el elemento observado es (o no) una instancia de una clase específica. O bien, los modelos de clasificación binaria predicen uno de dos resultados mutuamente excluyentes. Por ejemplo:

- Si un paciente corre riesgo de padecer diabetes en función de parámetros clínicos como el peso, la edad, el nivel de glucosa, etc.
- Si un cliente bancario dejará de pagar un préstamo en función de sus ingresos, historial crediticio, edad y otros factores.

Vigilada Mineducación

## CLASIFICACIÓN BINARIA

En la clasificación binaria, la etiqueta determina si el elemento observado es (o no) una instancia de una clase específica. O bien, los modelos de clasificación binaria predicen uno de dos resultados mutuamente excluyentes. Por ejemplo:

- Si un paciente corre riesgo de padecer diabetes en función de parámetros clínicos como el peso, la edad, el nivel de glucosa, etc.
- Si un cliente bancario dejará de pagar un préstamo en función de sus ingresos, historial crediticio, edad y otros factores.
- Si un pasajero del Titanic sobrevivió o no.

Vigilada Mineducación

## CLASIFICACIÓN MULTICLASE

La clasificación multiclase amplía la clasificación binaria para predecir una etiqueta que representa una de varias clases posibles.

Por ejemplo:

Vigilada Mineducación

## CLASIFICACIÓN MULTICLASE

La clasificación multiclase amplía la clasificación binaria para predecir una etiqueta que representa una de varias clases posibles. Por ejemplo:

- Las especies de pingüino (Adelie, Gentoo o Chinstrap) se basan en sus mediciones físicas.

Vigilada Mineducación

## CLASIFICACIÓN MULTICLASE

La clasificación multiclase amplía la clasificación binaria para predecir una etiqueta que representa una de varias clases posibles. Por ejemplo:

- Las especies de pingüino (Adelie, Gentoo o Chinstrap) se basan en sus mediciones físicas.
- La especie de una orquídea (Setosa, Versicolor,irginica).

Vigilada Mineducación

## CLASIFICACIÓN MULTICLASE

La clasificación multiclase amplía la clasificación binaria para predecir una etiqueta que representa una de varias clases posibles. Por ejemplo:

- Las especies de pingüino (Adelie, Gentoo o Chinstrap) se basan en sus mediciones físicas.
- La especie de una orquídea (Setosa, Versicolor,irginica).
- El género de una película (comedia, terror, romance, aventura o ciencia ficción) en función de su reparto, director y presupuesto.

Vigilada Mineducación

# CLASIFICACIÓN MULTICLASE

```
df = sns.load_dataset('penguins')
df
```

Visualize

| | species object | island object | bill_length_mm fl... | bill_depth_mm fl... | flipper_length_mm | body_mass_g flo... | sex object |
|---|---|---|---|---|---|---|---|
| | Adelie 44.2%<br>Gentoo 36%<br>Chinstrap 19.8% | Biscoe 48.8%<br>Dream 36%<br>Torgersen 15.1% | 32.1 - 59.6 | 13.1 - 21.5 | 172.0 - 231.0 | 2700.0 - 6300.0 | Male 48.8%<br>Female 48%<br>Missing 3.2% |
| 0 | Adelie | Torgersen | 39.1 | 18.7 | 181 | 3750 | Male |
| 1 | Adelie | Torgersen | 39.5 | 17.4 | | | |
| 2 | Adelie | Torgersen | 40.3 | 18 | | | |
| 3 | Adelie | Torgersen | nan | nan | | | |
| 4 | Adelie | Torgersen | 36.7 | 19.3 | | | |
| 5 | Adelie | Torgersen | 39.3 | 20.6 | | | |
| 6 | Adelie | Torgersen | 38.9 | 17.8 | | | |
| 7 | Adelie | Torgersen | 39.2 | 19.6 | | | |
| 8 | Adelie | Torgersen | 34.1 | 18.1 | | | |
| 9 | Adelie | Torgersen | 42 | 20.2 | | | |

344 rows, 7 cols 10 / page « ‹ Page 1 of 35 › »

```
df = pd.read_csv('iris.csv')
df
```

| | sepal.length floa... | sepal.width float... | petal.length float... | petal.width float64 | variety object |
|---|---|---|---|---|---|
| | 4.3 - 7.9 | 2.0 - 4.4 | 1.0 - 6.9 | 0.1 - 2.5 | Setosa 33.3%<br>Versicolor 33.3%<br>Virginica 33.3% |
| 0 | 5.1 | 3.5 | 1.4 | 0.2 | Setosa |
| 1 | 4.9 | 3 | 1.4 | 0.2 | Setosa |
| 2 | 4.7 | 3.2 | 1.3 | 0.2 | Setosa |
| 3 | 4.6 | 3.1 | 1.5 | 0.2 | Setosa |
| 4 | 5 | 3.6 | 1.4 | 0.2 | Setosa |
| 5 | 5.4 | 3.9 | 1.7 | 0.4 | Setosa |
| 6 | 4.6 | 3.4 | 1.4 | 0.3 | Setosa |
| 7 | 5 | 3.4 | 1.5 | 0.2 | Setosa |
| 8 | 4.4 | 2.9 | 1.4 | 0.2 | Setosa |
| 9 | 4.9 | 3.1 | 1.5 | 0.1 | Setosa |

150 rows, 5 cols 10 / page « ‹ Page 1 of 15 › »

Vigilada Mineducación

# MÉTRICAS DE EVALUACIÓN

**¿Cómo sabemos si el modelo realmente funciona?**

**¿Cómo sabemos si es bueno, si es útil, o si simplemente "adivinó" bien por casualidad?**

Las métricas de evaluación son un conjunto de puntuaciones objetivas que nos dicen exactamente qué tan bien (o qué tan mal) se está desempeñando nuestro modelo.

Vigilada Mineducación

# MÉTRICAS DE EVALUACIÓN

Usamos métricas por tres razones principales:

- **Medir el Rendimiento:** Cuantifican el "desempeño" del modelo en datos que nunca ha visto (el set de prueba).

Vigilada Mineducación

# MÉTRICAS DE EVALUACIÓN

Usamos métricas por tres razones principales:

- **Medir el Rendimiento:** Cuantifican el "desempeño" del modelo en datos que nunca ha visto (el set de prueba).
- **Comparar Modelos:** Nos permiten decidir objetivamente modelo es mejor que otro para nuestro problema.

Vigilada Mineducación

# MÉTRICAS DE EVALUACIÓN

Usamos métricas por tres razones principales:

- **Medir el Rendimiento:** Cuantifican el "desempeño" del modelo en datos que nunca ha visto (el set de prueba).
- **Comparar Modelos:** Nos permiten decidir objetivamente modelo es mejor que otro para nuestro problema.
- **Entender los Errores:** No solo nos dicen *si* el modelo se equivoca, sino *cómo* y *dónde* se está equivocando.

Vigilada Mineducación

# MÉTRICAS DE EVALUACIÓN PARA CLASIFICACIÓN

## Accuracy Score (Exactitud)

Es la métrica más simple e intuitiva, ya que responde a la pregunta ¿Qué porcentaje del total de predicciones acertó el modelo?

Vigilada Mineducación

# MÉTRICAS DE EVALUACIÓN PARA CLASIFICACIÓN

## Accuracy Score (Exactitud)

Es la métrica más simple e intuitiva, ya que responde a la pregunta ¿Qué porcentaje del total de predicciones acertó el modelo?

**Cómo se interpreta:**

- Se calcula como: (Aciertos Totales / Total de Predicciones)
- Un **Accuracy Score** de 0.95 significa que el modelo acertó el 95% de las veces en el set de prueba.

Es una gran métrica, pero puede ser engañosa si las clases están muy desbalanceadas (ej. un dataset con 99% de pingüinos "Adelie" y 1% de "Chinstrap").

Vigilada Mineducación

# MÉTRICAS DE EVALUACIÓN PARA CLASIFICACIÓN

## Confusion Matrix (Matriz de Confusión)

Es una "radiografía" detallada de los aciertos y errores del modelo. Indica no solo si el modelo se equivocó, sino cómo se equivocó.

**Cómo se interpreta:**

- Es una tabla que cruza el Valor Real (la verdad) contra el Valor Predicho (lo que dijo el modelo).
- La diagonal principal muestra todos los aciertos.
- Un número fuera de la diagonal es un error (una “confusión”).
- Permite ver exactamente dónde se confunde el modelo.

Vigilada Mineducación

Institución Universitaria
Reacreditada en Alta Calidad

# ¡MUCHAS GRACIAS!

Material de apoyo usado para las clases de Introducción a la Ciencia de Datos

Elaborado por:
**Esteban Gonzalez Valencia**
estebangonzalez@itm.edu.co

Hacia una era de Universidad y Humanidad